

HENRIQUE LIMA GUSMÃO

LISTAS PÚBLICAS DE PROCURADOS NÃO MEDEM CRIMINALIDADE

Auditoria sociotécnica da estabilidade e dos limites inferenciais de um pipeline de similaridade facial

Public wanted-person lists do not measure criminality: a sociotechnical audit of stability and inferential limits in a face-similarity pipeline

Monografia técnico-científica independente - 1ª edição

BELO HORIZONTE
2026

Publicação técnico-científica independente na área de Ciência da Computação

Título: Listas Públicas De Procurados Não Medem Criminalidade: Auditoria sociotécnica da estabilidade e dos limites inferenciais de um pipeline de similaridade facial

Autor: Henrique Lima Gusmão

Instituição: Universidade Federal de Minas Gerais, Instituto de Ciências Exatas, Departamento de Ciência da Computação, Belo Horizonte, MG, Brasil.

Natureza da publicação: monografia técnico-científica independente de pesquisa original, autoria individual, sem revisão por pares.

Área do conhecimento: Ciência da Computação.

Subáreas: inteligência artificial, aprendizagem de máquina, visão computacional, auditoria algorítmica, ética em IA, vies de seleção e avaliação de sistemas de similaridade facial.

Edição: 1ª edição

Data de publicação da 1ª edição: 30 de julho de 2026, Belo Horizonte

ISBN: 978-65-02-26124-8

DOI: [10.5281/zenodo.21659240](https://doi.org/10.5281/zenodo.21659240)

© 2026 Henrique Lima Gusmão. Esta obra está licenciada sob a Creative Commons Attribution 4.0 International — CC BY 4.0.

As opiniões e conclusões apresentadas são de responsabilidade exclusiva do autor e não representam necessariamente posicionamento institucional da UFMG.

FICHA CATALOGRÁFICA

G984I Gusmão, Henrique Lima.
Listas Públicas De Procurados Não Medem Criminalidade: Auditoria sociotécnica da estabilidade e dos limites inferenciais de um pipeline de similaridade facial / Henrique Lima Gusmão. – 1. ed. – Belo Horizonte: edição do autor, 2026.
1 recurso online: il., quadros, tabelas. Inclui referências e apêndice.
ISBN: 978-65-02-26124-8 DOI: 10.5281/zenodo.21659240
1. Inteligência artificial. 2. Reconhecimento facial. 3. Auditoria algorítmica. 4. Vies racial. 5. Ética em inteligência artificial. 6. Vies de seleção. I. Título.
CDD 006.3

Cite:

GUSMÃO, Henrique Lima. Listas Públicas De Procurados Não Medem Criminalidade: Auditoria sociotécnica da estabilidade e dos limites inferenciais de um pipeline de similaridade facial. 1. ed. Belo Horizonte: edição do autor, 2026. Publicação eletrônica depositada no Zenodo. DOI: 10.5281/zenodo.21659240. ISBN: 978-65-02-26124-8.

RESUMO

Esta monografia investiga uma falha recorrente em sistemas de inteligência artificial: o pipeline produz um rótulo a partir de uma representação, recupera esse rótulo com alta separabilidade e converte a circularidade em aparente evidência sobre pessoas. Propõe-se um framework de auditoria de construtos endógenos que distingue separabilidade interna, estabilidade computacional, validade de construto e validade externa. O caso empírico audita um pipeline de similaridade facial aplicado a listas públicas de procurados, que são produtos de seleção institucional e não amostras probabilísticas da criminalidade. Na reconstrução agrupada, 9.482 embeddings válidos foram avaliados por cross-fitting sem ajuste no teste. A ROC-AUC média foi 0,896, indicando recuperabilidade interna do alvo sintético, não mensuração de criminalidade. A análise de estabilidade reuniu 611 configurações e 60.045 comparações pareadas; em $k = 64$, as medianas foram 0,085 para ARI e 0,004 para Jaccard do alvo. Um controle sintético confirmou, em três demonstrações, que um alvo induzido pela geometria pode ser altamente separável e mudar quando o agrupamento é perturbado. Em braço independente com FairFace, os cenários demográficos apresentaram, contra a referência, ARI mediano de 0,182 a 0,199 e Jaccard próximo de 0,001, embora a prevalência do alvo e a ROC-AUC variassem pouco. Como a identidade das imagens e a inicialização também variam, o experimento não identifica efeito causal demográfico. Os resultados demonstram a falácia da separabilidade endógena: recuperar um rótulo produzido pelo próprio sistema não estabelece a existência nem a validade de um construto externo.

Palavras-chave: validade de construto; viés de seleção; reconhecimento facial; auditoria algorítmica; fisionomia algorítmica.

ABSTRACT

This monograph examines a recurring failure in artificial-intelligence systems: a pipeline produces a label from a representation, recovers that label with high separability, and converts this circularity into apparent evidence about people. It proposes an audit framework for endogenous constructs that distinguishes internal separability, computational stability, construct validity, and external validity. The empirical case audits a face-similarity pipeline applied to public wanted-person lists, which are products of institutional selection rather than probability samples of criminality. In the grouped reconstruction, 9,482 valid embeddings were evaluated by cross-fitting with no test-set fitting. Mean ROC-AUC was 0.896, indicating internal recoverability of the synthetic target rather than measurement of criminality. The stability analysis comprised 611 configurations and 60,045 pairwise comparisons; at $k = 64$, median ARI was 0.085 and median target Jaccard was 0.004. A synthetic control confirmed in three demonstrations that a geometry-induced target can be highly separable and change when clustering is perturbed. In an independent FairFace arm, demographic scenarios yielded median ARI values from 0.182 to 0.199 and target Jaccard near 0.001 against the reference, while target prevalence and ROC-AUC changed little. Because image membership and initialization also vary, the experiment does not identify a causal demographic effect. The results demonstrate the endogenous-separability fallacy: recovering a label produced by the system itself does not establish the existence or validity of an external construct.

Keywords: construct validity; selection bias; face recognition; algorithmic auditing; algorithmic physiognomy.

SUMÁRIO

1 INTRODUÇÃO.....	1
1.1 Contribuições	2
1.2 Trabalhos relacionados e fundamentação	2
2 MATERIAIS E MÉTODOS	3
2.1 Unidade de análise e estado preservado	3
2.2 Framework de auditoria da separabilidade endógena.....	4
2.3 Classes de identificabilidade	4
2.4 Cadeia sociotécnica de seleção e status da evidência	5
2.5 Proveniência de fonte e análises excluídas	6
2.6 Análise de estabilidade computacional	6
2.7 Avaliação agrupada e contrato de reprodução.....	7
2.7.1 Construção e limites do group_id	8
2.8 Níveis de verificabilidade computacional.....	9
2.9 Experimento externo de composição demográfica.....	9
3 RESULTADOS	10
3.1 Fluxo de registros e cobertura técnica	10
3.2 Lacunas de proveniência e estado histórico	11
3.3 Estabilidade computacional da partição	11
3.4 Avaliação agrupada: histórico preservado e reconstrução atual	12
3.5 Controle sintético e paradoxo separabilidade–estabilidade	13
3.6 Experimento externo: composição demográfica e estrutura do pipeline	14
4 DISCUSSÃO.....	16
4.1 Recuperabilidade interna não é validade de construto.....	16
4.2 A falácia da separabilidade endógena	17
4.3 Criminalidade não é atributo facial: validade de construto e fisiognomia algorítmica	17

4.4 Estabilidade computacional.....	18
4.5 Raça, seleção institucional e o que o corpus atual não permite medir..	18
4.6 Ética: reproduzir o viés para demonstrá-lo não autoriza operacionalizá-lo	19
4.7 Contribuição científica: separar a demonstração do viés de afirmações sobre pessoas	20
5 LIMITAÇÕES E AGENDA DE REPRODUÇÃO	21
6 CONCLUSÃO	22
DECLARAÇÕES.....	22
REFERÊNCIAS	24
APÊNDICE A — RASTREABILIDADE E CONTRATO DE REPRODUÇÃO ..	27

1 INTRODUÇÃO

Esta monografia investiga como uma regularidade produzida por um sistema de inteligência artificial pode adquirir aparência de descoberta sobre seres humanos. O caso de listas públicas de procurados é deliberadamente crítico: fotografias institucionalmente selecionadas são transformadas em embeddings, agrupadas e pontuadas, embora o corpus não contenha uma variável observável que represente criminalidade. A questão central deixa de ser se um rosto revela crime e passa a ser como detectar a conversão de circularidade computacional em alegação substantiva.

Listas públicas de procurados registram pessoas que determinadas instituições decidiram localizar e divulgar em certo momento. Não são levantamentos probabilísticos de delitos, autores ou populações. Na Interpol, a Red Notice é um pedido de localização e prisão provisória; apenas parte dos avisos se torna pública, e a observação depende de jurisdição, política de divulgação, vigência, disponibilidade de fotografia e capacidade de coleta (Interpol, 2026a, 2026b). Esse encadeamento seleciona o universo observado antes de qualquer modelo.

A dimensão racial torna o problema especialmente sensível. Desigualdades documentadas no sistema penal e em procedimentos de reconhecimento coexistem com bases biométricas cuja composição e qualidade afetam os erros. No Brasil, 55,5% da população se autodeclarou preta ou parda no Censo 2022; estatísticas penais e recomendações do CNJ também registram disparidades relevantes (IBGE, 2022; Conselho Nacional de Justiça, 2022; Secretaria Nacional de Políticas Penais, 2025). Esses dados contextualizam o risco sociotécnico, mas não autorizam atribuir raça/cor às imagens do corpus nem estimar seletividade racial sem metadados por registro e denominadores compatíveis.

O problema formal aparece quando o pipeline deriva um alvo Y de uma representação $Z = f(X)$ e avalia um score $g(Z)$ contra esse mesmo alvo. Uma AUC alta pode então demonstrar apenas recuperabilidade da regra construída. Chama-se aqui falácia da separabilidade endógena a passagem indevida da recuperabilidade de Y para a existência ou validade de um construto externo C . A auditoria deve separar quatro perguntas: o alvo é separável, é estável, mede o construto alegado e se generaliza para uma população definida?

A monografia audita o estado preservado e a reconstrução final do repositório are-you-a-criminal-ML. O desenho combina análise de identificabilidade, linhagem de dados, cross-fitting agrupado, controles negativos, estabilidade sob perturbações e

um braço externo com FairFace. O objetivo não é construir um detector de criminalidade, mas oferecer um protocolo reutilizável para reconhecer quando um sistema transforma seus próprios rótulos em aparente evidência científica.

As perguntas de pesquisa são: RQ1 — quais decisões institucionais e técnicas condicionam o corpus e seus limites externos? RQ2 — qual é a separabilidade interna do alvo endógeno? RQ3 — quão estáveis são a partição e a identidade do alvo sob mudanças de seed, k, ordem, minibatch e representação? RQ4 — quais alegações sobre criminalidade, raça e populações permanecem não identificáveis?

1.1 Contribuições

C1 — contribuição conceitual. Distingue separabilidade, estabilidade, validade de construto e validade externa.

C2 — contribuição metodológica. Formaliza uma matriz de identificabilidade e verificabilidade para alegações sociotécnicas.

C3 — contribuição computacional. Integra linhagem, auditoria de vazamento, cross-fitting agrupado, controles negativos e estabilidade pairwise.

C4 — contribuição empírica. Mostra que métricas agregadas podem permanecer altas enquanto a partição e a identidade do alvo variam substancialmente.

C5 — contribuição sociotécnica. Trata seleção institucional, publicação, coleta e processamento como partes do sistema avaliado.

1.2 Trabalhos relacionados e fundamentação

O enquadramento articula seis literaturas: crítica à fisionomia algorítmica; validade de construto e mensuração; viés de seleção; auditoria de datasets e modelos; reconhecimento facial e diferenças demográficas; e associações entre aparência e categorias sociais ou morais em modelos multimodais. Bowyer et al. (2020) demonstram a fragilidade da suposta ‘criminalidade pela face’; Jacobs e Wallach (2021) mostram que mensuração e fairness dependem da validade do construto; Raji et al. (2020, 2022) situam auditoria e alegações de funcionalidade ao longo do ciclo de vida do sistema.

O problema permanece atual em modelos multimodais. Birhane et al. (2024) avaliaram 14 modelos visiolinguísticos e observaram associações racializadas com a classe ‘criminal’, cujo comportamento mudou com a escala do modelo e do conjunto de treinamento. O resultado não equivale ao experimento desta monografia, mas

reforça que rótulos morais podem emergir de escolhas de dados, classes e representação, exigindo auditoria de sua proveniência e significado.

Na biometria, a avaliação contínua do NIST destaca que diferenças demográficas de erro dependem do algoritmo, da tarefa e da qualidade da imagem (NIST, 2026). FairFace foi criado para estudar desequilíbrios de atributos em um domínio próprio e fornece categorias históricas de anotação, não uma ontologia biológica nem autoidentificação irrestrita (Kärkkäinen; Joo, 2021). Por isso, o braço externo é tratado como análise de sensibilidade de composição, sem transferência de rótulos ao corpus principal.

2 MATERIAIS E MÉTODOS

2.1 Unidade de análise e estado preservado

A unidade observada é um registro público coletado, não uma ocorrência criminal nem, necessariamente, uma pessoa única. Foram considerados manifestos, imagens alinhadas, embeddings ArcFace de 512 dimensões, relatórios de pré-processamento, código e saídas da auditoria. O estado histórico de referência declarado na edição anterior é o commit

734f5979b0b659727c71b07c77ee7f0b9431d2b9, associado ao depósito Zenodo então utilizado. A corrida científica final possui manifesto próprio, configuração final e hashes de entrada/saída. Esse manifesto registra o commit Git f90298a8962e1b612ec3463bdf1013f6bb0b543b e marca a árvore de trabalho como modificada; portanto, o hash do commit não é, isoladamente, uma identificação byte a byte do estado executado. A tag pública 1.1, posterior, organiza o código e os relatórios da melhoria de reprodutibilidade, mas é tratada como empacotamento posterior, não como prova automática de equivalência integral com a árvore usada na corrida.

A documentação contemporânea foi usada para localizar implementação e artefatos da auditoria final, sem imputar retroativamente seus parâmetros ao pipeline histórico. Essa separação é essencial: cluster-alvo, cross-fitting agrupado, PCA-64 especificada, calibração, limiares, auditoria de group_id e desenho ampliado de estabilidade pertencem à reconstrução atual; regras históricas ausentes permanecem não recuperadas (Gusmão, 2026).

2.2 Framework de auditoria da separabilidade endógena

Seja X o dado observado, $Z = f(X)$ uma representação, $Y = h(Z)$ um alvo produzido ou selecionado pelo pipeline e $s = g(Z)$ um score avaliado contra Y . A falácia ocorre quando o sucesso de s em recuperar Y é apresentado como evidência de que Y mede um construto externo C . A implicação recuperabilidade(Y) $\Rightarrow$ validade(C) não é lógica nem empiricamente garantida.

$$Y = h(f(X)); s = g(f(X)); \text{separabilidade}(s, Y) \not\Rightarrow \text{existência ou validade de } C$$

O framework audita quatro planos. (1) Separabilidade interna: ROC-AUC e PR-AUC respondem quão bem o score ordena o alvo endógeno. (2) Estabilidade: ARI, Jaccard e prevalência respondem quanto a partição e o alvo dependem de escolhas computacionais. (3) Validade de construto: requer evidência de que Y representa C , e não apenas a geometria que o gerou. (4) Validade externa: requer população-alvo, denominadores, seleção observável e condições de generalização. Cada plano bloqueia uma inferência distinta.

O protocolo operacional consiste em localizar a origem de Y ; separar ajuste, seleção e avaliação; executar controles que rompam a relação geométrica; perturbar sementes, hiperparâmetros, ordem e representação; e classificar como não identificável toda alegação externa sem variável, comparador ou denominador observável. O caso de ‘criminalidade facial’ funciona como demonstração construtiva dessa falha, mas o protocolo também se aplica a inferências de personalidade, empregabilidade, periculosidade, emoção ou orientação política.

2.3 Classes de identificabilidade

Cada alegação foi classificada antes da interpretação. “Identificável” designa uma grandeza para a qual unidade, variável e denominador são observáveis no estado preservado. “Diagnosticável” designa uma propriedade interna que pode ser testada sem representar o construto social de interesse. “Não identificável” designa um estimando para o qual faltam variáveis, comparadores, denominadores ou contrafactuais essenciais. “Parcialmente verificável” foi reservado a resultados existentes cujos números podem ser localizados, mas cujo procedimento completo não pode ser reconstruído independentemente.


Quadro 1 — Matriz de auditoria, evidência e identificabilidade

Alegação	Unidade/denominador	Evidência disponível	Classe
Fluxo técnico atual	Linha/estágio do manifesto	Manifesto final, hashes e relatórios	Identificável
Cobertura de extração	Embedding por registro	9.584 registros; 9.482 vetores válidos	Identificável
Relação 9.546↔9.584	Estados históricos distintos	Sem elo documental recuperado	Não identificável
Estabilidade computacional atual	Execuções/pares sob perturbação	611 execuções; ARI/Jaccard pairwise	Diagnosticável
Recuperação agrupada atual	Dobra por group_id provável	5 dobras; métricas e auditoria de ajuste	Diagnosticável
ROC/PR históricos	Dobra do estado preservado	0,930/0,479 reportados; protocolo histórico incompleto	Parcialmente verificável
Influência por fonte	Fonte e denominadores institucionais	Fonte analítica não recuperada	Não identificável
Composição/seletividade racial do corpus	Raça/cor documentada e denominadores comparáveis	Rótulos raciais validados e denominadores ausentes	Não identificável
Equidade biométrica por grupo	Pares genuínos/impostores, grupos e protocolo	Identidade confirmada e protocolo biométrico ausentes	Não identificável

Fonte: elaboração própria. “Diagnosticável” descreve a operação interna do pipeline, não sua validade externa.

2.4 Cadeia sociotécnica de seleção e status da evidência

A inclusão final foi representada como condicionamento em $S = 1$. O símbolo resume, para fins analíticos, transições distintas: decisão institucional de localizar e divulgar, permanência na página, disponibilidade de fotografia, coleta, padronização, detecção facial e extração válida. O modelo não estima efeitos causais; ele organiza mecanismos de seleção que limitam o universo observável (Elwert; Winship, 2014; Hernán; Hernández-Díaz; Robins, 2004).

Figura 1 — Cadeia sociotécnica, endogeneidade do alvo e limites inferenciais.

Fonte: elaboração própria. O diagrama distingue seleção/observabilidade, geometria interna e o vínculo externo que precisaria ser demonstrado.

Quadro 2 — Transições de seleção e observabilidade no estado auditado

Transição	Mecanismo de inclusão/exclusão	Evidência por registro	Status
Decisão institucional	Investigação, jurisdição, pedido e prioridade	Não disponível	Não observável por registro
Publicidade e vigência	Publicação, permanência, retirada ou localização	Datas e motivo não confiáveis	Não identificável temporalmente
Coleta	Página acessível e captura técnica	Contagem agregada herdada	Reconciliação documental
Padronização	Formato, download e processamento	Contagens agregadas herdadas	Reconciliação documental
Manifesto analítico	Registro admitido no conjunto final	9.584 linhas reproduzidas	Reproduzido/verificado
Extração de embedding	Face detectável e vetor válido	9.482 vetores; 102 falhas	Reproduzido/verificado

Fonte: elaboração própria a partir dos artefatos e das limitações de proveniência declaradas no estado preservado.

2.5 Proveniência de fonte e análises excluídas

A variável de fonte permanece não recuperada no manifesto analítico que sustenta a avaliação final. Assim, enriquecimento por fonte, previsibilidade de fonte, balanceamento, leave-one-source-out, efeito causal de fonte e composição temporal não são estimados. A auditoria também não reconstrói datas institucionais de inclusão/remoção. Essas ausências são preservadas como limites de proveniência, e não preenchidas por nomes de arquivos ou inferência ad hoc.

Os resultados são classificados pela sua relação com a evidência. As contagens 11.724, 9.764 e 9.546 são histórico preservado documentado; 9.584 e 9.482 foram reproduzidas no estado atual; a ligação histórica entre 9.546 e 9.584 permanece não recuperada. As métricas ROC-AUC 0,930 e PR-AUC 0,479 da edição anterior continuam apenas como resultados históricos reportados. Já o cross-fitting, os limiares/calibração, PCA-64, group_id e a estabilidade ampliada são reconstruções ou análises novas da auditoria final, sem atribuição retroativa ao pipeline histórico.

2.6 Análise de estabilidade computacional

A auditoria final separa três tipos de instabilidade: estocástica, operacional e de representação. O desenho estocástico combina 100 sementes explícitas com $k = 32, 48, 64, 80, 96$ e 128 , totalizando 600 execuções com ordem original, representação L2 e batch_size primário. A instabilidade operacional é examinada por quatro ordens (original, reversa, embaralhamento com semente e índice ordenado por hash) e por

cinco `batch_size` (256, 512, 1.024, 2.048 e 4.096). A instabilidade de representação compara `original_l2` e PCA-64. O desenho completo contém 611 execuções e foi concluído integralmente.

O agrupamento reconstruído usa `MiniBatchKMeans`. A configuração primária fixa `k = 64`, `batch_size = 1.024`, `max_iter = 100` e `n_init = 3`; o primeiro valor da lista explícita de sementes atua como semente primária nas análises operacionais e de representação. O cluster-alvo é o maior cluster. Para a partição completa usa-se ARI; para o conjunto-alvo, Jaccard. A análise final calcula também tamanho e prevalência do alvo. Em vez de comparar todas as soluções contra uma única referência, as partições de cada grupo comparável são avaliadas em pares e resumidas por distribuição; a execução produziu 60.045 comparações pairwise, evitando que a conclusão dependa de uma referência arbitrária.

ARI é interpretado como concordância de partições corrigida pelo acaso e Jaccard como sobreposição do conjunto-alvo, $J(A,B)=|A\cap B|/|A\cup B|$ (Hubert; Arabie, 1985; von Luxburg, 2010). Essas métricas diagnosticam dependência computacional dentro da região de configurações examinada; não validam uma partição substantiva, identidade, categoria social ou propriedade jurídica. A edição anterior continha oito contrastes contra uma referência com ARI de 0,072 a 0,113 e Jaccard de 0 a 0,124; esses valores são mantidos apenas como subconjunto documentado da reconstrução anterior, não como resumo estatístico da corrida final ampliada.

PCA-64 é uma reconstrução atual explicitamente especificada, não uma configuração histórica recuperada: 64 componentes, `solver randomized`, `random_state = 20260727`, `centering = true`, `whitening = false`, normalização L2 antes e depois da transformação. Na avaliação por dobra, a PCA — quando utilizada — é ajustada exclusivamente no treino e aplicada ao teste; na análise de sensibilidade de representação sobre todos os registros, seu escopo é declarado separadamente. A especificação e a variância explicada são registradas em `pca_specification.json`. Nenhum desses parâmetros é atribuído ao procedimento histórico ausente.

2.7 Avaliação agrupada e contrato de reprodução

Cross-fitting é empregado aqui como separação agrupada de ajuste e avaliação, não como inferência semiparamétrica. A reconstrução final usa `GroupKFold` com cinco dobras definidas por `group_id` de duplicidade provável. Em cada dobra, a representação ajustável, o `MiniBatchKMeans`, a escolha do cluster-alvo, o centroide,

a calibração logística e o limiar são ajustados exclusivamente no treino. O conjunto de teste é transformado sem reajuste; o modelo de clustering treinado prediz o rótulo de cluster do teste e o alvo binário é definido por pertencimento ao cluster-alvo escolhido no treino. O score bruto é a similaridade com o centroide-alvo; quando há duas classes no treino, uma regressão logística treinada apenas no treino produz o score probabilístico.

Algoritmo 1 — Protocolo executado de cross-fitting agrupado

1. Particionar registros com GroupKFold por group_id provável, sem grupo compartilhado entre treino e teste.
2. Ajustar qualquer representação aprendida somente no treino e apenas transformar o teste.
3. Ajustar MiniBatchKMeans somente no treino.
4. Selecionar, somente no treino, o maior cluster como alvo e construir y_train.
5. Calcular o centroide do alvo no treino e pontuar treino/teste por similaridade com esse centroide.
6. Produzir y_test por model.predict(test) e pertencimento ao rótulo do cluster-alvo selecionado no treino.
7. Ajustar calibração logística somente no treino quando houver duas classes.
8. Selecionar o limiar somente no treino pelo máximo F1 da curva precisão-revocação.
9. Avaliar o teste uma única vez; registrar prevalência, grupos, limiar, calibração, métricas e hash do estado de treino.
10. Auditar cada etapa ajustada e falhar se houver índice de teste ou registro fora do treino.

A auditoria de ajuste registrou 25 eventos em cinco dobras e encontrou zero sobreposição com o teste e zero ajustes fora do treino. Isso fortalece a validade interna da reconstrução atual contra vazamento direto treino/teste. Não elimina, porém, a endogeneidade conceitual: y_train e y_test são definidos pelo próprio clustering treinado e projetado no espaço de embeddings, portanto as métricas medem recuperação de um alvo sintético reconstruído, não correspondência com um critério externo.

Limiar e calibração estão agora metodologicamente especificados para a reconstrução atual. A calibração é logística e ajustada somente no treino; por isso o Brier pode ser interpretado como erro quadrático probabilístico em relação ao alvo sintético desta reconstrução. Essa interpretação não é transferível para probabilidade de criminalidade, culpa, identidade ou qualquer atributo humano. Os números históricos antigos continuam separados: o protocolo que produziu ROC-AUC 0,930 e PR-AUC 0,479 não foi integralmente recuperado e não deve ser presumido idêntico ao protocolo atual.

2.7.1 Construção e limites do group_id

Na reconstrução atual, group_id é um agrupamento conservador de duplicidade provável baseado em embeddings L2-normalizados e similaridade cosseno. Pares com similaridade pelo menos 0,999 são conectados e componentes são formados por

union-find; identificadores públicos dos grupos são pseudonimizados. Foram obtidos 9.422 grupos prováveis entre 9.482 registros, dos quais 59 são não unitários; 1,255% dos registros pertencem a grupos com mais de um registro. O limiar primário 0,999 é uma escolha metodológica da auditoria atual, não uma identidade biométrica validada nem um parâmetro histórico recuperado.

A separação agrupada garante que nenhum `group_id` provável acesse treino e teste. Isso controla duplicidades conforme a heurística construída, mas não prova que a mesma pessoa não possa ocorrer em grupos diferentes. A rotina gera uma amostra pseudonimizada de pares próximos ao limiar para revisão, porém o próprio artefato marca a revisão manual como não realizada; logo, não se reivindica validação humana do limiar nem confirmação de identidade.

2.8 Níveis de verificabilidade computacional

Quadro 3 — Escada de verificabilidade computacional

Nível	Critério	Situação neste estudo
Rastreabilidade	Localizar código, entradas, configuração e outputs	Alta para a auditoria final: manifesto, hashes, <code>run_id</code> e 20 outputs registrados; histórica incompleta
Reexecução	Executar o protocolo atual no ambiente declarado	Realizada na configuração final; 611/611 execuções de estabilidade e 5 dobras agrupadas
Reprodução numérica atual	Obter novamente resultados do protocolo reconstruído	9.584 e 9.482 reproduzidos; métricas atuais e outputs estruturados registrados
Reprodução histórica	Reconstituir integralmente o procedimento antigo	Parcial: ROC/PR antigos e regras históricas centrais permanecem apenas preservados/não recuperados
Replicação independente	Nova equipe/dados/protocolo externo	Não realizada

Fonte: elaboração própria. A escada separa localização de artefatos, reexecução, reprodução numérica e replicação externa.

2.9 Experimento externo de composição demográfica

Como o corpus principal não possui raça/cor documentada nem vínculo verificável com bases demográficas externas, a sensibilidade à composição foi examinada em braço independente com FairFace (Kärkkäinen; Joo, 2021). Foram usadas apenas as sete categorias fornecidas pela base; nenhuma categoria foi inferida visualmente ou transferida ao pipeline de procurados. Cada cenário contém 36.456 registros sem reposição. As proporções foram controladas, mas a identidade

específica das imagens também varia entre cenários; portanto, o desenho não isola o efeito da proporção demográfica do efeito da amostragem de registros.

A liberação `margin025`, recortada e alinhada upstream com `dlib.get_face_chip()`, foi fornecida diretamente ao reconhecedor do pacote `InsightFace buffalo_l`. A implementação usa `InsightFace 1.0.1`, `ONNX Runtime 1.18.1`, leitura RGB com conversão para BGR, normalização de pixels e redimensionamento executados pelo reconhecedor, embedding de 512 dimensões e normalização L2 posterior. O arquivo de reconhecimento disponível no ambiente é `w600k_r50.onnx`, mas seu hash não foi incorporado ao manifesto da corrida; por isso, o SHA-256 observado posteriormente não é atribuído retroativamente à execução. `MiniBatchKMeans`, `n_init = 3`, `batch_size = 1.024`, `max_iter = 100`, regra do maior cluster, score cosseno e avaliação foram mantidos constantes.

As comparações entre cenários usam apenas a interseção dos identificadores presentes em ambos. Os limites $ARI < 0,90$, $Jaccard < 0,80$, $|\Delta \text{prevalência}| \geq 0,02$ e $|\Delta AUC| \geq 0,03$ foram pré-declarados como heurísticas descritivas para organizar a leitura, não como limiares de significância ou relevância substantiva validados externamente. A inferência principal usa distribuições e tamanhos de efeito contínuos.

3 RESULTADOS

3.1 Fluxo de registros e cobertura técnica

A corrida final reproduz 9.584 linhas no manifesto analítico e 9.482 embeddings válidos de 512 dimensões. As contagens 11.724, 9.764 e 9.546 foram preservadas como artefatos históricos documentados, mas não reclassificadas como reproduzidas. A relação entre o estado histórico de 9.546 e o manifesto de 9.584 continua sem elo documental recuperado; por isso não se calcula taxa de retenção entre esses estados nem se força uma única coorte retrospectiva.

Tabela 1 — Quantidades por estágio e status da evidência

Estágio/contagem	n	Status da evidência
Coleta bruta histórica	11.724	Histórico preservado/documentado
Entrada na padronização histórica	9.764	Histórico preservado/documentado
Processamento bem-sucedido histórico	9.546	Histórico preservado/documentado

Estágio/contagem	n	Status da evidência
Manifesto analítico atual	9.584	Reproduzido/verificado no artefato atual
Embeddings válidos atuais	9.482	Reproduzido/verificado no artefato atual

Fonte: auditoria de linhagem da execução final. As cinco contagens pertencem a estados de evidência distintos; a relação 9.546↔9.584 permanece não recuperada e não é usada para calcular retenção.

3.2 Lacunas de proveniência e estado histórico

A proveniência por fonte e por tempo permanece não identificável. O manifesto público da auditoria final usa source = unresolved para os registros pseudonimizados; não há denominadores institucionais nem painel confiável de entradas/remoções. Consequentemente, a execução final não estima influência institucional, enriquecimento por fonte, composição temporal ou seletividade racial. A impressão visual de maior ou menor presença de qualquer grupo nas páginas coletadas não é tratada como dado racial: sem raça/cor documentada por registro, transformá-la em porcentagem exigiria uma classificação visual que o próprio estudo considera metodologicamente inadequada e eticamente arriscada.

A principal melhora de linhagem é classificatória, não retrospectiva: a auditoria passa a registrar explicitamente o que é histórico preservado, reproduzido, reconstruído, novo ou não recuperado. Essa distinção impede que números localizados em relatórios antigos sejam tratados como se tivessem sido reobtidos pelo protocolo atual.

3.3 Estabilidade computacional da partição

Tabela 2 — Estabilidade estocástica por k: medianas, IQR e intervalos P05–P95.

k	ARI mediana (IQR)	ARI P05–P95	Jaccard mediana (IQR)	Jaccard P05–P95	Prevalência mediana (IQR)
32	0.113 (0.104–0.123)	0.095–0.142	0.001 (0.000–0.020)	0.000–0.437	0.052 (0.049–0.055)
48	0.091 (0.084–0.099)	0.077–0.112	0.001 (0.000–0.051)	0.000–0.166	0.044 (0.041–0.047)
64	0.085 (0.078–0.092)	0.071–0.104	0.004 (0.000–0.047)	0.000–0.126	0.041 (0.038–0.044)
80	0.077 (0.072–0.083)	0.066–0.094	0.038 (0.004–0.066)	0.000–0.110	0.042 (0.038–0.047)
96	0.073 (0.069–0.079)	0.063–0.089	0.042 (0.013–0.073)	0.000–0.123	0.043 (0.040–0.048)
128	0.070 (0.065–0.075)	0.060–0.085	0.051 (0.027–0.079)	0.000–0.123	0.047 (0.041–0.051)

Fonte: stability_summary.csv. Para ARI e Jaccard, $n = 4.950$ pares distintos por k ; para prevalência, $n = 100$ execuções por k . IQR = $Q1-Q3$.

A corrida final torna visível o resultado das 60.045 comparações. Entre sementes, a mediana do ARI diminuiu de 0,113 em $k = 32$ para 0,070 em $k = 128$. A mediana do Jaccard do conjunto-alvo permaneceu entre 0,001 e 0,051; em $k = 64$ foi

0,004 (IQR 0,000–0,047; P05–P95 0,000–0,126). Esses valores mostram baixa concordância tanto da partição completa quanto da identidade do maior cluster na região examinada.

A sensibilidade não se restringiu à semente. Em $k = 64$, mudanças de ordem produziram ARI mediano 0,100 e Jaccard 0,000; mudanças de `batch_size`, ARI 0,085 e Jaccard 0,003; o contraste original $L2 \times PCA-64$ resultou em ARI 0,090 e Jaccard 0,000. A prevalência do alvo também variou: entre `batch_size`, a mediana foi 0,040 e o intervalo observado 0,028–0,125. Como o desenho cobre uma grade finita, os resultados sustentam instabilidade condicionada às perturbações executadas, não uma afirmação universal sobre todo algoritmo de clustering.

3.4 Avaliação agrupada: histórico preservado e reconstrução atual

Dois conjuntos de resultados devem ser mantidos separados. O estado histórico preserva ROC-AUC média de 0,930 e PR-AUC de 0,479 em cinco dobras, mas sua regra histórica completa de geração do alvo, prevalências, limiares e calibração não foi recuperada; esses números permanecem parcialmente verificáveis. A auditoria final executou um protocolo novo e explícito de cross-fitting agrupado, com cinco dobras, `group_id` provável, ajuste apenas no treino, calibração logística e limiar selecionado no treino. As métricas atuais medem exclusivamente recuperação interna do alvo sintético reconstruído.

Tabela 3 — Resultados históricos preservados e reconstrução agrupada atual

Métrica	Histórico preservado	Reconstrução atual final
ROC-AUC	0,930 (média reportada; protocolo histórico incompleto)	0,896
PR-AUC	0,479 (média reportada; baseline histórica não auditável)	0,348
Baseline PR-AUC	Não recuperada	0,054
Brier	Não interpretado por calibração histórica não recuperada	0,043
Balanced accuracy	Não usada como evidência principal	0,649563
F1	Não usada como evidência principal	0,338413
Precisão	Não usada como evidência principal	0,370329
Revocação	Não usada como evidência principal	0,333153


Fonte: histórico preservado na edição anterior e FINAL_REPRODUCTION_REPORT/cross_fitted_metrics.csv para a reconstrução final. Os resultados atuais não são apresentados como reprodução do procedimento histórico.

Na reconstrução atual, a ROC-AUC média foi 0,896, com variação entre dobras de 0,882 a 0,904. A PR-AUC média foi 0,348 (0,211–0,448), frente a baseline média 0,054, e o Brier médio foi 0,043 (0,034–0,049). Os arquivos finais preservam métricas agregadas por cinco dobras, mas não previsões por observação; por isso, não se apresenta um intervalo bootstrap que não possa ser reconstruído de modo verificável. Esses números quantificam recuperabilidade interna do alvo sintético, não desempenho para criminalidade, culpa, raça/cor ou outro atributo externo.

A auditoria registrou 25 eventos de ajuste em cinco dobras, todos com `test_overlap = 0` e `outside_train = 0`; `group_id` também não atravessou as divisões. Essa evidência sustenta a ausência de vazamento direto conforme a unidade de bloqueio construída. Como `group_id` representa apenas duplicidade provável, não se afirma ausência absoluta de uma mesma pessoa em grupos diferentes.

3.5 Controle sintético e paradoxo separabilidade–estabilidade

O controle sintético passou nas três demonstrações pré-definidas. O clustering gerou um alvo sem variável social externa; um score derivado da mesma geometria recuperou esse alvo com ROC-AUC = 1,000; e a perturbação de $k = 3$ para $k = 4$ mudou completamente o conjunto-alvo (Jaccard = 0,000). O controle não representa pessoas nem prova um efeito no corpus principal. Ele isola o mecanismo lógico: separabilidade perfeita pode coexistir com ausência de validade externa e com identidade instável do alvo.

Figura 2 — Paradoxo separabilidade–estabilidade na reconstrução final.

Fonte: elaboração própria a partir de `cross_fitted_metrics.csv` e `stability_summary.csv`. As métricas do painel A avaliam o alvo endógeno; os demais painéis resumem perturbações de seed e k.

3.6 Experimento externo: composição demográfica e estrutura do pipeline

O braço externo mostra que cenários com proporções demográficas diferentes podem produzir estruturas materialmente distintas. Em $k = 64$, B, C e D apresentaram, contra A, ARI mediano de 0,182, 0,199 e 0,189 e Jaccard mediano do alvo próximo de 0,001. Esses contrastes incluem, contudo, tanto a mudança de proporção quanto a mudança dos registros amostrados e ocorrem sobre forte instabilidade entre sementes; não identificam efeito causal demográfico.

Tabela 4 — Resultados do experimento externo de composição demográfica em $k = 64$

Cenário	Prevalência do alvo	ARI vs. A	Jaccard do alvo vs. A	ROC-AUC	PR-AUC
A	0,025	—	—	0,908	0,448
B	0,026	0,182	0,001	0,903	0,440
C	0,027	0,199	0,001	0,893	0,400
D	0,025	0,189	0,001	0,910	0,466

Fonte: `DEMOGRAPHIC_COMPOSITION_EXPERIMENT` e tabelas estruturadas da execução. Categorias demográficas permanecem restritas ao FairFace e não são transferidas ao corpus principal.

O ponto decisivo é que a mudança estrutural não veio acompanhada de mudança equivalente nas métricas agregadas. A prevalência mediana do maior cluster permaneceu entre 0,025 e 0,027 e a ROC-AUC entre 0,893 e 0,910. A PR-AUC apresentou mudança relevante apenas em C, cenário de sub-representação, caindo de 0,448 para 0,400 ($\Delta = -0,048$). Assim, um indicador de desempenho pode parecer praticamente estável enquanto a partição interna e a identidade do conjunto-alvo mudam substancialmente.

A interpretação exige, porém, um controle adicional: o próprio clustering é muito instável entre sementes. Em $k = 64$, o ARI mediano entre seeds variou de 0,186 a 0,198 e o Jaccard mediano do alvo de 0,000 a 0,015 nos quatro cenários. Portanto, a baixa concordância entre A e os cenários perturbados não pode ser atribuída exclusivamente à composição demográfica; ela ocorre sobre uma geometria que já é fortemente dependente da inicialização. O resultado mais defensável é a coexistência de duas propriedades: composição e configuração afetam a estrutura encontrada, enquanto algumas métricas de recuperação interna permanecem altas.




Figura 3 — Composição média do cluster-alvo por categoria fornecida pelo FairFace, em $k = 64$ e ao longo das sementes.

Fonte: *target_demographic_distribution.svg*. As proporções descrevem somente o cluster sintético deste benchmark; não representam criminalidade, risco ou propensão de qualquer grupo.

A composição do próprio cluster-alvo acompanhou as intervenções de amostragem, mas de forma não trivial. A participação média da categoria `Middle Eastern` no alvo foi 14,4% em A, 24,7% em B, 12,6% em C e 31,8% em D. Esses

valores não são taxas de erro nem estimativas de comportamento; são proporções condicionadas a um alvo que muda entre execuções. Na grade de k , a prevalência mediana do maior cluster variou aproximadamente de 0,017 a 0,048 em todos os cenários, enquanto as diferenças A–D permaneceram pequenas para um mesmo k . Isso mostra que a escolha do número de clusters pode alterar a prevalência do alvo mais do que a perturbação demográfica testada, reforçando a necessidade de tratar hiperparâmetros como parte da evidência e não como detalhe neutro de implementação.




Figura 4 — Estabilidade entre sementes no experimento externo, em $k = 64$.

Fonte: *stability.svg*. ARI resume a concordância da partição; *target_jaccard*, a sobreposição do maior cluster entre execuções.

Os rótulos do FairFace são categorias históricas fornecidas pelo dataset, não autoidentificação nem verdade biológica. O experimento não estabelece diferenças intrínsecas entre grupos e não autoriza transferir seus resultados para pessoas procuradas. Sua função é metodológica: mostrar, em um domínio separado, que composição da base, hiperparâmetros e aleatoriedade podem alterar o padrão que o algoritmo apresenta como estrutura objetiva.

4 DISCUSSÃO

4.1 Recuperabilidade interna não é validade de construto

O cross-fitting mostra que a regra geométrica reconstruída é recuperável fora da amostra, mesmo com ajuste confinado ao treino. A ROC-AUC média de 0,896

deve, portanto, ser lida como recuperabilidade interna do alvo endógeno. A avaliação responde corretamente à pergunta computacional definida pelo pipeline, mas essa pergunta não é equivalente a medir criminalidade.

Separabilidade e estabilidade respondem a perguntas diferentes. A primeira avalia quão bem a regra construída é recuperada; a segunda, quanto a própria regra depende de decisões computacionais. A validade de construto exige ainda evidência independente de que o alvo mede o conceito nomeado, e a validade externa exige população, seleção e condições de generalização definidas. O framework impede que sucesso em um plano seja usado como atalho para os demais.

4.2 A falácia da separabilidade endógena

Clustering, escolha do maior cluster, centroide, calibração, score e rótulo de teste permanecem relacionados à mesma geometria. Evitar vazamento direto melhora a validade interna, mas não cria um vínculo entre Y e um construto externo C . A falácia da separabilidade endógena surge quando a correção da operação $g(Z) \rightarrow Y$ é usada para sustentar uma alegação sobre C . O controle sintético torna essa distinção observável sem recorrer a propriedades humanas.

Os resultados históricos e atuais, por isso, não devem ser fundidos. O antigo 0,930/0,479 é evidência preservada de uma execução cujo contrato completo não foi recuperado. O atual 0,896/0,348 pertence a um protocolo reconstruído, auditável e mais restritivo quanto ao vazamento. A diferença numérica entre eles não prova melhora, piora ou descoberta de uma propriedade facial; apenas descreve execuções distintas de regras computacionais distintas.

4.3 Criminalidade não é atributo facial: validade de construto e fisionomia algorítmica

Aparência facial, identidade, raça/cor, condição jurídica e criminalidade são grandezas distintas. Embeddings ArcFace foram desenvolvidos para discriminação de identidades em protocolos específicos; seu uso em agrupamentos não converte distância facial em caráter, culpa ou propensão criminal (Deng et al., 2019; Jacobs; Wallach, 2021). A literatura que critica a inferência de “criminalidade pela face” mostra que classificadores aparentemente eficazes podem explorar composição de base, condições de captura, estilo de fotografia e outros atalhos experimentais. Isso

aproxima esse tipo de uso da fisiognomia algorítmica: uma aparência de mensuração científica aplicada a um construto que não foi validado (Bowyer et al., 2020).

A designação original do projeto é mantida apenas como provocação crítica. A saída do pipeline é, no máximo, similaridade relativa a um corpus selecionado e a um alvo construído. Não existe base observacional nesta monografia para interpretar proximidade geométrica como probabilidade de crime, “tendência criminal”, periculosidade ou pertencimento a uma categoria humana externa. O ponto acadêmico é justamente demonstrar como uma interpretação indevida pode parecer quantitativamente convincente.

4.4 Estabilidade computacional

As distribuições completas tornam a instabilidade um resultado, e não apenas um item de protocolo. ARI e Jaccard baixos aparecem em seeds, ordem, batch_size e representação, enquanto a prevalência varia de modo diferente. A escolha de k também altera a prevalência do maior cluster e a concordância das partições. Logo, seed, k, ordem, minibatch, representação e regra de seleção do alvo devem ser tratados como componentes da evidência, não detalhes neutros de implementação (von Luxburg, 2010).

Os resultados permanecem condicionados à grade executada e ao MiniBatchKMeans. Eles não identificam uma partição verdadeira, mas rejeitam a apresentação de uma única solução como estrutura inevitável dos dados. Uma auditoria completa deve reportar distribuições, tamanho e prevalência do alvo, além das métricas de separabilidade.

4.5 Raça, seleção institucional e o que o corpus atual não permite medir

O corpus não é amostra probabilística. A inclusão depende de investigação, decisão de divulgação, vigência da publicação, jurisdição, disponibilidade de fotografia, coleta e processamento. A seleção ocorre antes do algoritmo e pode criar associações que o pipeline apenas preserva ou amplifica. Em um sistema penal no qual desigualdades raciais são documentadas, essa cadeia de seleção precisa ser tratada como parte do objeto científico, e não como ruído externo.

A dimensão racial, contudo, não pode ser resolvida por inspeção visual das fotografias. O estado atual não recuperou de forma adequada a variável de fonte, as datas institucionais nem raça/cor declarada por registro. Assim, a percepção exploratória de que determinado grupo parece pouco ou muito representado nas listas

é uma hipótese para investigação, não um resultado. Uma análise racial defensável exigiria, no mínimo, fonte por registro, categorias raciais explicitamente documentadas, preservação das categorias nativas de cada jurisdição, denominadores compatíveis e análise de sensibilidade. Sem esses elementos, a seletividade racial permanece não identificável, e “adivinhar” raça a partir do rosto acrescentaria um segundo problema de validade ao primeiro.

O experimento externo não resolve essa ausência e foi desenhado justamente para não fazê-lo. FairFace permanece um domínio analítico separado: seus rótulos não têm vínculo verificável com os registros, embeddings ou alvo sintético das listas de procurados. Ainda assim, o braço controlado acrescenta uma demonstração empírica importante. Alterar a composição da base produziu partições e conjuntos-alvo materialmente diferentes, enquanto prevalência e ROC-AUC permaneceram quase constantes. Em termos de aprendizagem de máquina, isso é evidência de dependência do conjunto e de instabilidade da representação agrupada; em estatística, é uma análise de sensibilidade; nas ciências sociais, mostra como composição e seleção antecedem a inferência; e, na ética computacional, demonstra por que desempenho agregado não deve ser confundido com neutralidade do sistema. O resultado não prova discriminação racial no corpus principal: demonstra um mecanismo pelo qual a composição de um conjunto pode alterar o que o algoritmo trata como padrão.

4.6 Ética: reproduzir o viés para demonstrá-lo não autoriza operacionalizá-lo

O valor ético do experimento depende de uma separação rigorosa entre demonstração e aplicação. No Brasil, origem racial ou étnica e dado biométrico vinculado a uma pessoa natural são dados pessoais sensíveis na LGPD; a condição de a fotografia já estar pública não elimina, por si só, os riscos do tratamento. A Recomendação da UNESCO sobre Ética da Inteligência Artificial enfatiza não discriminação, avaliação de impacto, privacidade, rastreabilidade e prevenção da reprodução de estereótipos. Como referência internacional adicional, o AI Act europeu proíbe, em seu âmbito, avaliações de risco criminal baseadas exclusivamente em perfil ou características pessoais e a categorização biométrica destinada a inferir raça (Brasil, 2018; UNESCO, 2022; União Europeia, 2024).

Por isso, este estudo não deve produzir um “score de criminalidade” individual, não deve inferir raça/cor a partir das imagens e não deve disponibilizar um endpoint que permita uso policial, empregatício, securitário ou reputacional. A reprodução

deliberada de viés só é cientificamente defensável quando serve como teste controlado de falha, com resultados agregados, minimização de dados, bloqueio de reidentificação e linguagem que impeça confundir diagnóstico de um sistema com diagnóstico de uma pessoa. A existência de embeddings faciais e métricas de similaridade, por si só, não autoriza reconhecimento de identidade nem análise de equidade biométrica operacional (Grother; Ngan; Hanaoka, 2019; ISO, 2021, 2024).

A separação entre os dois domínios é também uma salvaguarda ética e epistemológica. No experimento externo, a proveniência do rótulo é explícita e permanece limitada ao FairFace; no corpus principal, a ausência de raça/cor permanece ausência. Não há transferência por nearest neighbor, similaridade de embeddings, clustering ou classificador treinado em outra base. Essa regra evita que uma incerteza documental seja convertida em um atributo aparentemente objetivo pela própria tecnologia que está sob auditoria. Em outras palavras, governança de rótulos e validade de construto são parte do sistema computacional, não anexos administrativos ao final do experimento.

4.7 Contribuição científica: separar a demonstração do viés de afirmações sobre pessoas

A auditoria final reduz limites internos, mas preserva os bloqueios inferenciais fundamentais. Cross-fitting, group_id provável, PCA-64 e a grade de estabilidade são reconstruídos e auditáveis. Permanecem, porém, a lacuna 9.546↔9.584, a ausência de fonte e datas confiáveis, as regras históricas de clustering e seleção do alvo, a falta de identidades confirmadas e, para a questão racial, a ausência de raça/cor validada por registro e denominadores compatíveis. Cada ausência bloqueia uma classe diferente de alegação e deve permanecer visível.

A contribuição de maior alcance é um método reutilizável para auditar construtos endógenos. A matriz de identificabilidade delimita as alegações possíveis; a linhagem localiza a origem do alvo; o cross-fitting testa recuperação sem ajuste no teste; controles negativos expõem a circularidade; e a estabilidade quantifica a dependência de escolhas computacionais. O caso de listas de procurados mostra por que a matemática do pipeline pode ser correta enquanto o nome atribuído à saída permanece cientificamente inválido.

O braço FairFace acrescenta uma análise de sensibilidade de composição, não uma validação racial do corpus principal. A coexistência de métricas agregadas

semelhantes, partições diferentes e forte variação entre seeds demonstra contingência do pipeline. Replicações pareadas de amostragem são necessárias antes de atribuir variação adicional à composição.

5 LIMITAÇÕES E AGENDA DE REPRODUÇÃO

Validade de construto, externa e racial. O alvo é sintético e endógeno à geometria facial; não mede criminalidade, culpa, raça/cor, identidade ou equidade. O corpus decorre de seleção institucional, divulgação, permanência pública, disponibilidade de fotografia, coleta e processamento, sem amostragem probabilística. A execução atual também não possui raça/cor validada por registro, fonte recuperada de forma suficiente nem denominadores institucionais comparáveis. Portanto, a monografia não estima a proporção de pessoas negras, brancas ou de qualquer outro grupo nas listas e não calcula seletividade racial. Essa ausência não deve ser preenchida por classificação visual ou por um modelo que infira raça a partir do rosto.

Braço demográfico externo. Os rótulos do FairFace são categorias históricas do dataset, não autoidentificação irrestrita nem categorias biológicas. Como cada cenário altera proporções e registros, e a estabilidade entre seeds é baixa, não se estima efeito causal demográfico. Uma extensão adequada exige 50–100 replicações independentes ou um desenho pareado que maximize um núcleo comum, permitindo decompor composição, amostragem, k , seed e interações.

Validade interna e de conclusão. Group_id bloqueia duplicidades prováveis no limiar 0,999, mas não foi validado manualmente e não garante identidade única. A análise futura deve revisar cegamente pares próximos a 0,995, 0,997, 0,999 e 0,9995 e repetir métricas por limiar. Também deve ablar a regra do alvo — maior cluster, cluster aleatório, mais compacto e mais separado — para quantificar a influência dessa convenção. Os limiares de relevância atuais permanecem heurísticos; distribuições contínuas sustentam a inferência principal.

Reprodutibilidade e agenda seguinte. A corrida registra 78 testes aprovados, hashes de 20 outputs, configuração e sementes, mas `worktree_dirty = true` impede tratá-la como artefato canônico imutável. A próxima liberação deve partir de tag limpa, ambiente congelado, pesos identificados por SHA-256, manifesto completo e depósito dos outputs estruturados com DOI. Predições por observação devem ser preservadas para intervalos bootstrap auditáveis. Os experimentos adicionais são agenda futura e não são apresentados como resultados desta edição.

6 CONCLUSÃO

A auditoria demonstra três fatos complementares. Primeiro, o corpus é condicionado por seleção institucional e técnica e, portanto, não representa criminalidade populacional. Segundo, o alvo endógeno é internamente recuperável: em 9.482 embeddings, o cross-fitting produziu ROC-AUC média 0,896. Terceiro, essa recuperabilidade coexiste com baixa estabilidade: em $k = 64$, as medianas entre sementes foram 0,085 para ARI e 0,004 para Jaccard do alvo. O controle sintético reproduziu o mecanismo com AUC 1,000 e mudança completa do alvo após perturbação do clustering.

O braço FairFace reforça a contingência sem sustentar causalidade racial: mudanças de composição e amostragem alteraram partições e conjuntos-alvo, enquanto prevalência e ROC-AUC variaram pouco, sobre forte instabilidade entre seeds. A contribuição geral é a distinção operacional entre separabilidade, estabilidade, validade de construto e validade externa. Quando Y é produzido a partir de Z e $g(Z)$ recupera Y , o desempenho pode ser matematicamente real e substantivamente circular. Auditar essa passagem — localizando a origem do rótulo, quantificando sua estabilidade e exigindo evidência independente para o construto externo — é aplicável a qualquer sistema que converta representações de pessoas em alegações sobre caráter, risco, capacidade ou identidade social.

DECLARAÇÕES

Disponibilidade de código e artefatos. Repositório público: github.com/limag-henrique/are-you-a-criminal-ML. Estado histórico de referência da edição anterior: commit

734f5979b0b659727c71b07c77ee7f0b9431d2b9. Manifesto da corrida final: `run_id final-2026-08-14T203722.484507+0000-211653f2`, `git_commit f90298a8962e1b612ec3463bdf1013f6bb0b543b`, com árvore de trabalho marcada como modificada. Tag pública posterior 1.1: “Melhora de índice de reprodutividade”. DOI de conceito: 10.5281/zenodo.21536403; registro versionado previamente citado: 10.5281/zenodo.21632858. O manifesto final registra hashes das entradas e de 20 outputs. O braço demográfico externo está isolado em ``research_audit_v2/demographic_composition/`` e é documentado por ``DEMOGRAPHIC_COMPOSITION_EXPERIMENT.md``, tabelas estruturadas, figuras SVG e manifesto próprio; esses artefatos devem acompanhar o depósito de reprodução para auditoria independente.

Não houve financiamento.

Conflitos de interesse. O autor desenvolveu o repositório auditado; esse conflito intelectual é declarado. Não foram informados conflitos financeiros adicionais nos documentos fornecidos.

Contribuições do autor (CRediT). H. L. Gusmão: **Conceitualização; Metodologia; Software; Curadoria de dados; Análise formal; Visualização; Redação — rascunho original; Redação — revisão e edição.**

Ética, raça e proteção de dados. Não houve recrutamento, intervenção ou contato com participantes. A auditoria secundária trabalha com artefatos computacionais derivados de fotografias previamente publicadas, mas dados públicos não são automaticamente isentos de risco. No Brasil, origem racial ou étnica e dado biométrico vinculado a pessoa natural integram categorias de dados pessoais sensíveis previstas na LGPD. Os outputs públicos deste estudo são agregados ou pseudonimizados; nomes, URLs, caminhos pessoais, imagens e embeddings individuais são bloqueados pelo scanner fail-closed. Não foram inferidas categorias raciais a partir da aparência, não foram produzidas alegações individuais e não se recomenda uso operacional, reidentificação, decisão automatizada sobre pessoas nem redistribuição desnecessária dos dados faciais. No braço FairFace, foram utilizadas somente as categorias fornecidas pela própria base, mantidas estritamente no domínio externo, sem associação ou transferência para indivíduos do corpus principal. Qualquer extensão racial futura sobre as listas deve usar apenas metadados documentados, justificar finalidade e necessidade, minimizar dados, preservar categorias e incertezas de origem e divulgar somente resultados agregados com proteção contra reidentificação.

REFERÊNCIAS

- BEN-HUR, A.; ELISSEEFF, A.; GUYON, I. A stability based method for discovering structure in clustered data. *Pacific Symposium on Biocomputing*, p. 6-17, 2002. DOI: 10.1142/9789812799623_0002. Disponível em: https://doi.org/10.1142/9789812799623_0002. Acesso em: 27 jul. 2026.
- BIRHANE, A.; DEHDASTIAN, S.; PRABHU, V. U.; BODDETI, V. The Dark Side of Dataset Scaling: Evaluating Racial Classification in Multimodal Models. In: *ACM CONFERENCE ON FAIRNESS, ACCOUNTABILITY, AND TRANSPARENCY*, 2024, Rio de Janeiro. Proceedings [...]. New York: ACM, 2024. DOI: 10.1145/3630106.3658968. Disponível em: <https://doi.org/10.1145/3630106.3658968>. Acesso em: 16 ago. 2026.
- BOWYER, K. W.; KING, M. C.; SCHEIRER, W. J.; VANGARA, K. The “Criminality From Face” Illusion. *IEEE Transactions on Technology and Society*, v. 1, n. 4, p. 175-183, 2020. DOI: 10.1109/TTS.2020.3032321.
- BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Brasília, DF: Presidência da República, 2018.
- CHERNOZHUKOV, V. et al. Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, v. 21, n. 1, p. C1-C68, 2018. DOI: 10.1111/ectj.12097. Disponível em: <https://doi.org/10.1111/ectj.12097>. Acesso em: 27 jul. 2026.
- CONSELHO NACIONAL DE JUSTIÇA. Resolução nº 484, de 19 de dezembro de 2022. Estabelece diretrizes para a realização do reconhecimento de pessoas em procedimentos e processos criminais e sua avaliação no âmbito do Poder Judiciário. Brasília, DF: CNJ, 2022.
- CONSELHO NACIONAL DE JUSTIÇA; PROGRAMA DAS NAÇÕES UNIDAS PARA O DESENVOLVIMENTO. Caderno temático de relações raciais: diretrizes gerais para atuação dos serviços penais. Brasília, DF: CNJ, 2024. Disponível em: <https://bibliotecadigital.cnj.jus.br/handle/123456789/939>. Acesso em: 27 jul. 2026.
- DENG, J. et al. ArcFace: additive angular margin loss for deep face recognition. In: *IEEE/CVF CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION*, 2019. Proceedings [...]. p. 4690-4699. DOI: 10.1109/CVPR.2019.00482. Disponível em: <https://doi.org/10.1109/CVPR.2019.00482>. Acesso em: 27 jul. 2026.
- ELWERT, F.; WINSHIP, C. Endogenous selection bias: the problem of conditioning on a collider variable. *Annual Review of Sociology*, v. 40, p. 31-53, 2014. DOI: 10.1146/annurev-soc-071913-043455. Disponível em: <https://doi.org/10.1146/annurev-soc-071913-043455>. Acesso em: 27 jul. 2026.
- GEBRU, T. et al. Datasheets for datasets. *Communications of the ACM*, v. 64, n. 12, p. 86-92, 2021. DOI: 10.1145/3458723. Disponível em: <https://doi.org/10.1145/3458723>. Acesso em: 27 jul. 2026.
- GROTHER, P.; NGAN, M.; HANAOKA, K. Face Recognition Vendor Test Part 3: demographic effects. Gaithersburg: NIST, 2019. (NISTIR 8280). DOI: 10.6028/NIST.IR.8280. Disponível em: <https://doi.org/10.6028/NIST.IR.8280>. Acesso em: 27 jul. 2026.

GUSMÃO, H. L. Face Profile ML / are-you-a-criminal-ML. GitHub, 2026. Estado histórico de referência: commit 734f5979b0b659727c71b07c77ee7f0b9431d2b9. Auditoria final: manifesto com git_commit f90298a8962e1b612ec3463bdf1013f6bb0b543b; tag 1.1, “Melhora de índice de reprodutividade”, publicada posteriormente. Disponível em: <https://github.com/limag-henrique/are-you-a-criminal-ML>. Acesso em: 14 ago. 2026.

HERNÁN, M. A.; HERNÁNDEZ-DÍAZ, S.; ROBINS, J. M. A structural approach to selection bias. *Epidemiology*, v. 15, n. 5, p. 615-625, 2004. DOI: 10.1097/01.ede.0000135174.63482.43. Disponível em: <https://pubmed.ncbi.nlm.nih.gov/15308962/>. Acesso em: 27 jul. 2026.

HUBERT, L.; ARABIE, P. Comparing partitions. *Journal of Classification*, v. 2, p. 193-218, 1985. DOI: 10.1007/BF01908075. Disponível em: <https://doi.org/10.1007/BF01908075>. Acesso em: 27 jul. 2026.

IBGE. Censo Demográfico 2022: população por cor ou raça. Rio de Janeiro: Instituto Brasileiro de Geografia e Estatística, 2022. Resultados do universo divulgados pelo IBGE.

INTERPOL. About Red Notices. Lyon: Interpol, 2026a. Disponível em: <https://www.interpol.int/en/How-we-work/Notices/Red-Notices>. Acesso em: 27 jul. 2026.

INTERPOL. View Red Notices. Lyon: Interpol, 2026b. Disponível em: <https://www.interpol.int/en/How-we-work/Notices/Red-Notices/View-Red-Notices>. Acesso em: 27 jul. 2026.

ISO. ISO/IEC 19795-10:2024: information technology — biometric performance testing and reporting — Part 10: quantifying biometric system performance variation across demographic groups. Geneva: ISO, 2024. Disponível em: <https://www.iso.org/standard/81223.html>. Acesso em: 27 jul. 2026.

ISO. ISO/IEC 19795-1:2021: information technology — biometric performance testing and reporting — Part 1: principles and framework. 2. ed. Geneva: ISO, 2021. Disponível em: <https://www.iso.org/standard/73515.html>. Acesso em: 27 jul. 2026.

JACOBS, A. Z.; WALLACH, H. Measurement and fairness. In: ACM CONFERENCE ON FAIRNESS, ACCOUNTABILITY, AND TRANSPARENCY, 2021. Proceedings [...]. p. 375-385. DOI: 10.1145/3442188.3445901. Disponível em: <https://doi.org/10.1145/3442188.3445901>. Acesso em: 27 jul. 2026.

KÄRKKÄINEN, K.; JOO, J. FairFace: Face Attribute Dataset for Balanced Race, Gender, and Age for Bias Measurement and Mitigation. In: IEEE/CVF WINTER CONFERENCE ON APPLICATIONS OF COMPUTER VISION, 2021. Proceedings [...]. p. 1548–1558. DOI: 10.1109/WACV48630.2021.00159. Disponível em: <https://doi.org/10.1109/WACV48630.2021.00159>. Acesso em: 16 ago. 2026.

KAUFMAN, S. et al. Leakage in data mining: formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, v. 6, n. 4, art. 15, 2012. DOI: 10.1145/2382577.2382579. Disponível em: <https://doi.org/10.1145/2382577.2382579>. Acesso em: 27 jul. 2026.

MITCHELL, M. et al. Model cards for model reporting. In: CONFERENCE ON FAIRNESS, ACCOUNTABILITY, AND TRANSPARENCY, 2019. Proceedings [...]. p. 220-229. DOI:

10.1145/3287560.3287596. Disponível em: <https://doi.org/10.1145/3287560.3287596>. Acesso em: 27 jul. 2026.

NIST. Face Recognition Technology Evaluation: Demographic Effects. Gaithersburg: National Institute of Standards and Technology, 2026. Disponível em: https://pages.nist.gov/frvt/html/frvt_demographics.html. Acesso em: 16 ago. 2026.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825-2830, 2011. Disponível em: <https://www.jmlr.org/papers/v12/pedregosa11a.html>. Acesso em: 27 jul. 2026.

RAJI, I. D. et al. Closing the AI accountability gap: defining an end-to-end framework for internal algorithmic auditing. In: *CONFERENCE ON FAIRNESS, ACCOUNTABILITY, AND TRANSPARENCY*, 2020. Proceedings [...]. p. 33-44. DOI: 10.1145/3351095.3372873. Disponível em: <https://doi.org/10.1145/3351095.3372873>. Acesso em: 27 jul. 2026.

RAJI, I. D.; KUMAR, I. E.; HOROWITZ, A.; SELBST, A. D. The Fallacy of AI Functionality. In: *ACM CONFERENCE ON FAIRNESS, ACCOUNTABILITY, AND TRANSPARENCY*, 2022. Proceedings [...]. p. 959-972. DOI: 10.1145/3531146.3533158. Disponível em: <https://doi.org/10.1145/3531146.3533158>. Acesso em: 16 ago. 2026.

ROBERTS, D. R. et al. Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, v. 40, n. 8, p. 913-929, 2017. DOI: 10.1111/ecog.02881. Disponível em: <https://doi.org/10.1111/ecog.02881>. Acesso em: 27 jul. 2026.

SAITO, T.; REHMSMEIER, M. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, v. 10, n. 3, e0118432, 2015. DOI: 10.1371/journal.pone.0118432. Disponível em: <https://doi.org/10.1371/journal.pone.0118432>. Acesso em: 27 jul. 2026.

SECRETARIA NACIONAL DE POLÍTICAS PENAS. Relatório de Informações Penais: 15º ciclo SISDEPEN, 2º semestre de 2023. Brasília, DF: SENAPPEN, 2024. Disponível em: <https://www.gov.br/senappen/pt-br/servicos/sisdepen/relatorios/relatorios-de-informacoes-penitenciarias/relatorio-2o-semester-de-2023.pdf>. Acesso em: 27 jul. 2026.

SECRETARIA NACIONAL DE POLÍTICAS PENAS. SENAPPEN realiza oficina nacional para construção de um sistema penal antirracista. Brasília, DF: Ministério da Justiça e Segurança Pública, 2025.

SURESH, H.; GUTTAG, J. A framework for understanding sources of harm throughout the machine learning life cycle. In: *EQUITY AND ACCESS IN ALGORITHMS, MECHANISMS, AND OPTIMIZATION*, 2021. Proceedings [...]. p. 1-9. DOI: 10.1145/3465416.3483305. Disponível em: <https://doi.org/10.1145/3465416.3483305>. Acesso em: 27 jul. 2026.

UNESCO. Recommendation on the Ethics of Artificial Intelligence. Paris: UNESCO, 2022.

UNIÃO EUROPEIA. Regulamento (UE) 2024/1689 do Parlamento Europeu e do Conselho, de 13 de junho de 2024, que estabelece regras harmonizadas em matéria de inteligência artificial (Artificial Intelligence Act). *Jornal Oficial da União Europeia*, 2024.

VON LUXBURG, U. Clustering stability: an overview. *Foundations and Trends in Machine Learning*, v. 2, n. 3, p. 235-274, 2010. DOI: 10.1561/22000000008. Disponível em: <https://doi.org/10.1561/22000000008>. Acesso em: 27 jul. 2026.

APÊNDICE A — RASTREABILIDADE E CONTRATO DE REPRODUÇÃO

Este apêndice distingue o que a auditoria final efetivamente preencheu do que permanece histórico ou não recuperado. A classificação evita transformar documentação posterior em procedimento histórico e registra os elementos necessários para replicação independente.

Quadro A.1 — Status do pacote de reprodução após a corrida final

Componente	Situação final	Classe/status
Cross-fitting e rótulo de teste	Implementados; model.predict(test) e alvo escolhido no treino	Reconstruído/novo
Auditoria de leakage	5 dobras; 25 eventos; zero test_overlap e outside_train	Novo/verificado
group_id	Similaridade cosseno; limiar 0,999; 9.422 grupos; 59 não unitários	Reconstruído; duplicidade provável
Revisão manual do limiar	Amostra pseudonimizada produzida; revisão manual não realizada	Limitação
Métricas por dobra	cross_fitted_metrics.csv e split_composition.csv	Reconstruído/estruturado
Calibração e limiar	Logística e limiar por F1; ambos train-only	Reconstruído
PCA-64	Especificação completa e variância explicada em JSON	Reconstruído; não histórico
Estabilidade	611 execuções; resumo e 60.045 comparações pairwise	Novo/reconstruído
Linhagem	Cinco contagens classificadas; 9.546↔9.584 sem elo	Parcial/não recuperado
Manifesto/hashes/privacidade	Manifesto completo, 20 outputs com SHA-256; gates de privacidade	Verificado para corrida atual

Fonte: artefatos da execução final e implementação da tag 1.1. “Reconstruído” não significa reprodução do protocolo histórico.

Quadro A.2 — Especificação da configuração computacional da reconstrução final

Os parâmetros abaixo pertencem à reconstrução final. Onde o procedimento histórico não foi recuperado, isso é indicado explicitamente e nenhuma atribuição retroativa é feita.

Elemento	Configuração final reconstruída	Status histórico / observação
Commit/estado de execução	git_commit f90298a...; worktree_dirty=true; run_id final-2026-08-14T203722...	Não identifica sozinho a árvore byte a byte; tag 1.1 é posterior
Dados analíticos	9.584 registros; 9.482 vetores ArcFace de 512 dimensões	Contagens atuais reproduzidas
Algoritmo de clustering	MiniBatchKMeans	Reconstrução atual; regra histórica não recuperada
k	Primário 64; grade 32, 48, 64, 80, 96, 128	Grade final executada; k histórico não recuperado
Sementes	100 sementes explícitas; primary seed = primeira da lista	Reconstrução atual; sementes históricas não recuperadas
batch_size	Primário 1.024; grade 256, 512, 1.024, 2.048, 4.096	Reconstrução atual
max_iter / n_init	100 / 3	Reconstrução atual
Ordens	original, reversed, seeded_shuffle, hashed_index	Sensibilidade operacional atual

Elemento	Configuração final reconstruída	Status histórico / observação
Regra do alvo	largest_cluster	Reconstrução atual; histórica não recuperada
group_id	Union-find sobre pares de embeddings L2 com cosine similarity $\geq 0,999$	Duplicidade provável, nunca identidade confirmada
PCA-64	64 comp.; randomized; random_state 20260727; centering=true; whiten=false; L2 antes/depois	Reconstrução atual; configuração histórica não recuperada
Cross-fitting	GroupKFold, 5 dobras; clustering/target/centroid/calibração/limiar train-only	Reconstrução atual
Calibração	LogisticRegression (lbfgs), train-only	Reconstrução atual
Limiar	Máximo F1 na curva precisão-revocação do treino	Reconstrução atual
Ambiente	Windows 11; Python 3.14.3; NumPy 2.4.2; pandas 3.0.0; scikit-learn 1.9.0; SciPy 1.17.1	Registrado na corrida final
Outputs	20 artefatos listados com SHA-256	Reprodutibilidade atual; outputs não equivalem a histórico Git

Quadro A.3 — Escopo final da estabilidade e controle metodológico

A estabilidade final foi desenhada por fatores separados. As estatísticas completas de ARI, Jaccard, tamanho e prevalência do alvo são artefatos estruturados; o quadro registra somente quantidades e escopo confirmados na evidência recebida.

Bloco	Quantidade/configuração	Interpretação
Estocástico	600 = 100 seeds $\times$ 6 valores de k	Distribuições condicionais por k
Ordem	4 execuções	Sensibilidade operacional à sequência
batch_size	5 execuções	Sensibilidade operacional ao minibatch
Representação	2 execuções	original_l2 vs. PCA-64 reconstruída
Total	611/611 execuções	Desenho final completo
Pairwise	60.045 comparações	ARI/Jaccard sem referência arbitrária
Controle sintético	3/3 demonstrações passaram	Demonstração metodológica; não evidência sobre pessoas ou grupos humanos

O controle sintético demonstra apenas que um alvo induzido pela própria geometria pode ser separável e, ao mesmo tempo, sensível a perturbações. Não fornece evidência empírica sobre pessoas procuradas, criminalidade, biometria ou grupos humanos. As análises de estabilidade tampouco identificam uma partição “verdadeira”; medem dependência computacional dentro do desenho executado.