

HENRIQUE LIMA GUSMÃO

**A falsa ideia de “criminalidade facial”: viés racial,
listas públicas de procurados e os limites da
similaridade facial**

*The false idea of “facial criminality”: racial bias, public wanted-person lists, and the limits
of face similarity*

Monografia técnico-científica independente — 1ª edição

BELO HORIZONTE

2026

EXPEDIENTE EDITORIAL

Publicação técnico-científica independente na área de Ciência da Computação.

Título: A falsa ideia de “criminalidade facial”: viés racial, listas públicas de procurados e os limites da similaridade facial

Autor: Henrique Lima Gusmão

Afiliação do autor: Universidade Federal de Minas Gerais, Instituto de Ciências Exatas, Departamento de Ciência da Computação, Belo Horizonte, MG, Brasil.

Natureza da publicação: monografia técnico-científica independente de pesquisa original, autoria individual, sem revisão por pares.

Área do conhecimento: Ciência da Computação.

Subáreas: inteligência artificial, aprendizagem de máquina, visão computacional, auditoria algorítmica, ética em IA, viés de seleção e avaliação de sistemas de similaridade facial.

Edição: 1ª edição — 19 ago. 2026

ISBN: 978-65-02-26124-8

DOI: [10.5281/zenodo.21659240](https://doi.org/10.5281/zenodo.21659240)

© 2026 Henrique Lima Gusmão. Esta obra está licenciada sob a Creative Commons Attribution 4.0 International — CC BY 4.0.

As opiniões e conclusões apresentadas são de responsabilidade exclusiva do autor e não representam necessariamente posicionamento institucional da UFMG.

FICHA CATALOGRÁFICA

G984I Gusmão, Henrique Lima.
A falsa ideia de “criminalidade facial”: viés racial, listas públicas de procurados e os limites da similaridade facial / Henrique Lima Gusmão. — 1. ed. — Belo Horizonte: edição do autor, 2026.
1 recurso online : il., quadros, tabelas.
Inclui referências e material suplementar.
ISBN: 978-65-02-26124-8
DOI: 10.5281/zenodo.21659240
1. Inteligência artificial. 2. Reconhecimento facial. 3. Auditoria algorítmica. 4. Viés racial. 5. Ética em inteligência artificial. 6. Viés de seleção. I. Título.
CDD 006.3

Como citar:

GUSMÃO, Henrique Lima. A falsa ideia de “criminalidade facial”: viés racial, listas públicas de procurados e os limites da similaridade facial. Belo Horizonte: edição do autor, 2026. DOI: 10.5281/zenodo.21659240. ISBN: 978-65-02-26124-8.

RESUMO

Este trabalho parte de uma pergunta deliberadamente provocativa: se uma máquina receber fotografias de listas públicas de procurados e for induzida a procurar nelas um suposto padrão de “criminalidade facial”, ela poderá produzir uma classificação estatisticamente convincente? O experimento foi construído para mostrar por que a resposta computacional pode parecer positiva enquanto a resposta científica continua negativa. O pipeline transforma rostos em embeddings, agrupa similaridades, define um alvo sintético a partir da própria geometria e avalia quão bem esse alvo pode ser recuperado. Assim, a máquina pode parecer ter aprendido “criminalidade” quando, na realidade, reaprendeu uma regra produzida pelo próprio sistema. Listas de procurados, além disso, são produtos de seleção institucional e não amostras probabilísticas da criminalidade. Na reconstrução final, 9.482 embeddings válidos foram avaliados por validação cruzada agrupada com ajuste estritamente no treino e produziram ROC-AUC média de 0,896 (IC bootstrap de 95%: 0,884–0,908) e PR-AUC de 0,348 (IC 95%: 0,315–0,394). A estabilidade foi examinada em 611 configurações e 60.045 comparações pareadas descritivas; em $k = 64$, as medianas foram 0,085 para ARI e 0,004 para Jaccard do alvo, evidenciando forte dependência da configuração. A Proposição 1, demonstrada por construção no script executável `<run_proposition_demo.py>`, mostra que alta separabilidade interna pode coexistir com desempenho ao acaso contra um critério externo independente; ela não prova baixa estabilidade. Um controle sintético atingiu ROC-AUC = 1,000 sem qualquer construto social externo, demonstrando que separabilidade perfeita pode ser inteiramente circular. Em braço independente com FairFace, perturbações de composição e amostragem estiveram associadas a mudanças materiais nas partições e na identidade do alvo, embora prevalência e ROC-AUC variassem pouco; como a identidade das imagens e a inicialização também variaram, o resultado não identifica efeito causal demográfico. A dimensão racial é central para a interpretação, mas o corpus principal não possui raça/cor validada por registro nem denominadores compatíveis, de modo que a percepção visual de maior ou menor presença de um grupo não é tratada como resultado. A conclusão é direta: a matemática do pipeline é real; não existe, porém, fundamento matemático neste estudo para ligar aparência facial a criminalidade. O trabalho mostra como seleção de dados, composição demográfica e rotulagem endógena podem dar aparência de objetividade a uma inferência preconceituosa e cientificamente inválida.

Palavras-chave: listas públicas de procurados; viés racial; viés de seleção; “criminalidade facial”; separabilidade endógena; validade de construto; auditoria algorítmica; similaridade facial.

ABSTRACT

This study starts from a deliberately provocative question: if a machine is given photographs from public wanted-person lists and is induced to search them for a supposed pattern of “facial criminality,” can it produce a statistically convincing classification? The experiment is designed to show why the computational answer may appear positive while the scientific answer remains negative. The pipeline turns faces into embeddings, clusters similarities, defines a synthetic target from the same facial geometry, and evaluates how well that target can be recovered. The system can therefore appear to have learned “criminality” when it has actually relearned a rule produced by its own representation. Wanted-person lists are also products of institutional selection rather than probability samples of criminality. In the final reconstruction, 9,482 valid embeddings were evaluated through grouped cross-validation with strictly train-only fitting, yielding mean ROC-AUC 0.896 (95% hierarchical-bootstrap CI: 0.884–0.908) and PR-AUC 0.348 (95% CI: 0.315–0.394). Stability was examined across 611 configurations and 60,045 descriptive pairwise comparisons; at $k = 64$, median ARI was 0.085 and median target Jaccard was 0.004, showing strong configuration dependence. Proposition 1, proved by construction in the executable script `<run_proposition_demo.py>`, establishes that high internal separability can coexist with chance performance against an independent external criterion; it does not prove low stability. A synthetic control reached ROC-AUC = 1.000 without any external social construct, demonstrating that perfect separability can be entirely circular. In an independent FairFace arm, composition and sampling perturbations were associated with material changes in partitions and target identity while target prevalence and ROC-AUC changed little; because image identity and initialization also varied, this does not identify a causal demographic effect. Race is central to the interpretation, but the main corpus lacks validated per-record race/color labels and compatible denominators, so visual impressions of over- or under-representation are not treated as findings. The conclusion is direct: the mathematics of the pipeline is real, but this study provides no mathematical basis for linking facial appearance to criminality. It shows how data selection, demographic composition, and endogenous labeling can give an appearance of objectivity to a prejudicial and scientifically invalid inference.

Keywords: public wanted-person lists; racial bias; selection bias; “facial criminality”; endogenous separability; construct validity; algorithmic auditing; face similarity.

LISTA DE FIGURAS

Figura 1 — Cadeia sociotécnica, endogeneidade do alvo e limites inferenciais.	8
Figura 2 — Paradoxo separabilidade–estabilidade na reconstrução final.	19
Figura 3 — Composição média do agrupamento-alvo por categoria fornecida pelo FairFace nos cenários A a D.	21
Figura 4 — Estabilidade entre sementes no experimento externo, em $k = 64$	22

LISTA DE TABELAS

Tabela 1 — Quantidades por estágio e status da evidência	16
Tabela 2 — Estabilidade estocástica por k : medianas, IQR e intervalos P05–P95.	17
Tabela 3 — Resultados históricos preservados e reconstrução agrupada atual	18
Tabela 4 — Resultados do experimento externo de composição demográfica em $k = 64$. . .	20

LISTA DE QUADROS

Quadro 1 — Trabalho anterior e contribuição integrada desta monografia	4
Quadro 2 — Matriz de auditoria, evidência e identificabilidade	8
Quadro 3 — Transições de seleção e observabilidade no estado auditado	9
Quadro 4 — Escada de verificabilidade computacional	13
Quadro 5 — Composição demográfica de entrada dos cenários A a D (FairFace)	14
Quadro A.1 — Status do pacote de reprodução após a corrida final	38
Quadro A.2 — Especificação da configuração computacional da reconstrução final	38
Quadro A.3 — Escopo final da estabilidade e controle metodológico	39

LISTA DE ABREVIATURAS E SIGLAS

Sigla	Significado
ARI	índice de Rand ajustado
CNJ	Conselho Nacional de Justiça
DOI	identificador de objeto digital
IA	inteligência artificial
IC	intervalo de confiança
IQR	intervalo interquartil
LGPD	Lei Geral de Proteção de Dados Pessoais
NIST	National Institute of Standards and Technology
OOF	predição fora da dobra (out-of-fold)
PCA	análise de componentes principais
PR-AUC	área sob a curva precisão-revocação
ROC-AUC	área sob a curva ROC
RQ	pergunta de pesquisa
SHA-256	algoritmo de hash seguro de 256 bits
UFMG	Universidade Federal de Minas Gerais

Sumário

1	INTRODUÇÃO	1
1.1	Contribuições	2
1.2	Trabalhos relacionados e fundamentação	3
2	MATERIAIS E MÉTODOS	6
2.1	Unidade de análise e estado preservado	6
2.2	Framework de auditoria da separabilidade endógena	6
2.3	Classes de identificabilidade	7
2.4	Cadeia sociotécnica de seleção e status da evidência	8
2.5	Proveniência de fonte e análises excluídas	9
2.6	Análise de estabilidade computacional	10
2.7	Validação cruzada agrupada e contrato de reprodução	11
2.7.1	Construção e limites do <code>group_id</code>	12
2.8	Níveis de verificabilidade computacional	13
2.9	Experimento externo de composição demográfica	13
2.9.1	Escopo da regra de definição do alvo	15
3	RESULTADOS	16
3.1	Fluxo de registros e cobertura técnica	16
3.2	Lacunas de proveniência e estado histórico	16
3.3	Estabilidade computacional da partição	17
3.4	Validação cruzada agrupada: histórico preservado e reconstrução atual	17
3.5	Resultado Empírico 1: paradoxo performance–estabilidade	19
3.6	Experimento externo: composição demográfica e estrutura do <i>pipeline</i>	20
4	DISCUSSÃO	23
4.1	Uma AUC alta não mede “criminalidade”	23
4.2	Como um viés ganha aparência matemática: a falácia da separabilidade endógena	23
4.3	Criminalidade não é atributo facial: validade de construto e fisionomia algorítmica	24
4.4	Estabilidade computacional	24
4.5	Raça e seleção: o que o experimento mostra — e o que não mostra	25
4.6	Reproduzir o viés para estudá-lo não autoriza usá-lo contra pessoas	25
4.7	Contribuição científica e social	26
5	LIMITAÇÕES E AGENDA DE REPRODUÇÃO	28
5.1	Validade de construto e de critério	28
5.2	Validade externa	28
5.3	Validade interna	28
5.4	Validade de conclusão e reprodutibilidade	28
6	CONCLUSÃO	30
	DECLARAÇÕES	32

REFERÊNCIAS	33
APÊNDICE A — RASTREABILIDADE E CONTRATO DE REPRODUÇÃO . . .	38

1 INTRODUÇÃO

A ideia original deste projeto foi simples e deliberadamente provocativa: reunir fotografias publicadas em listas de procurados e induzir um algoritmo a procurar nelas um suposto padrão de “criminalidade facial”. A intenção nunca foi defender que esse padrão exista. Foi construir, em ambiente controlado, uma máquina capaz de produzir uma resposta aparentemente convincente e então auditar por que essa resposta pode ser circular, preconceituosa e cientificamente vazia. Em termos práticos, o experimento pergunta: se o próprio sistema transforma rostos em uma regra, cria um alvo a partir dessa regra e depois é avaliado por reconhecê-lo, até que ponto uma boa métrica descreve o mundo — e até que ponto apenas descreve o próprio algoritmo?

As listas públicas de procurados foram escolhidas justamente porque parecem, à primeira vista, um banco de “criminosos”, mas não são isso em sentido estatístico. Elas registram pessoas que determinadas instituições decidiram localizar e divulgar em certo momento. Não são levantamentos probabilísticos de delitos, de autores de crimes ou da população. Na Interpol, por exemplo, a Red Notice é um pedido de localização e prisão provisória; apenas parte dos avisos se torna pública, e o que pode ser coletado depende de jurisdição, política de divulgação, vigência, disponibilidade de fotografia e capacidade de coleta (Interpol, 2026a, 2026b). Portanto, antes de qualquer linha de código, já existe uma cadeia de seleção que define quem pode aparecer no corpus.

A questão racial foi uma das motivações centrais do trabalho. A observação exploratória das listas despertou a impressão de que a composição visual do corpus não acompanhava de modo óbvio as desigualdades raciais documentadas no sistema penal. Essa impressão não é tratada como medição: o estudo não “adivinha” raça pela fotografia e não afirma que pessoas negras estejam mais ou menos presentes nas listas sem metadados válidos. Ela é transformada em pergunta científica. No Brasil, 55,5% da população se autodeclarou preta ou parda no Censo 2022; a SENAPPEN informou, para dezembro de 2024, 64% de pessoas negras entre as pessoas presas em celas físicas; e a Resolução CNJ nº 484/2022 registra levantamento nacional no qual 83% das pessoas apontadas em reconhecimentos fotográficos equivocados eram negras (IBGE, 2022; Secretaria Nacional de Políticas Penais, 2025; Conselho Nacional de Justiça, 2022). Esses números não são denominadores intercambiáveis e não calculam a composição das listas. Eles mostram por que o risco de transformar seleção institucional e aparência em “verdade matemática” tem relevância racial concreta.

O mecanismo computacional é menos complexo do que a linguagem técnica

pode sugerir. O pipeline deriva um alvo Y da própria representação facial $Z = f(X)$ e depois avalia um escore $g(Z)$ contra esse alvo. Se o alvo nasceu da geometria facial e o escore também nasce dela, uma AUC alta pode significar apenas que o sistema consegue recuperar a regra que ajudou a criar. Chamamos de falácia da separabilidade endógena a passagem indevida desse sucesso interno para uma afirmação externa — por exemplo, concluir que o padrão representa criminalidade, periculosidade, raça ou caráter. A métrica pode estar matematicamente correta e a interpretação, ainda assim, estar errada.

A monografia audita o estado preservado e a reconstrução final do repositório are-you-a-criminal-ML. A análise combina linhagem de dados, controle de vazamento, validação cruzada agrupada com ajuste estritamente no treino, estabilidade sob sementes e hiperparâmetros, controles negativos e um braço externo com FairFace. O objetivo não é construir um detector de criminalidade. É demonstrar, com código, números e rastreabilidade, como um sistema pode fabricar um padrão interno, como esse padrão varia sob perturbações de composição e configuração da base e por que nenhum desses resultados autoriza transformar similaridade facial em julgamento sobre pessoas.

RESULTADO EMPÍRICO 1, EM LINGUAGEM DIRETA — a validação agrupada produziu ROC-AUC média de 0,896 (IC bootstrap hierárquico de 95%: 0,884–0,908), enquanto a análise de estabilidade encontrou Jaccard mediano do alvo de 0,004 entre sementes. São diagnósticos complementares, obtidos em desenhos distintos: o primeiro mede recuperabilidade interna; o segundo, variação da identidade do alvo. Nenhum deles estabelece validade de construto.

As perguntas de pesquisa são: RQ-A — elevada separabilidade fora da amostra pode surgir sem evidência de validade de construto ou de critério? RQ-B — o alvo permanece substantivamente compatível sob especificações computacionais plausíveis? RQ-C — como seleção institucional, composição, amostragem e configuração condicionam o padrão produzido? A impossibilidade de observar quem ficou fora das listas é tratada como limite de identificabilidade da cadeia sociotécnica, não como quantidade empiricamente estimada.

1.1 Contribuições

C-A — contribuição teórica. As Proposições 1 e 2 separam, respectivamente, separabilidade de validade de critério e separabilidade de unicidade do alvo; o controle sintético e a construção executável em `<scripts/run_proposition_demo.py>` verificam o primeiro mecanismo sem atribuir significado social ao alvo.

C-B — contribuição metodológica e computacional. Separa recuperabilidade,

estabilidade, validade de construto, validade de critério e validade externa; integra linhagem, auditoria de vazamento, OOF individual, IC bootstrap hierárquico e 611 configurações de estabilidade.

C-C — contribuição sociotécnica e empírica. Mostra que seleção institucional, composição e configuração pertencem à evidência, quantifica a sensibilidade do `group_id` e delimita o braço FairFace como estudo associativo, sem inferir raça pela face nem efeito causal demográfico.

1.2 Trabalhos relacionados e fundamentação

O enquadramento articula validade de construto e mensuração, rótulos-proxy, subespecificação, indeterminação de rótulos, viés de seleção, auditoria de datasets e modelos, reconhecimento facial e crítica à fisiognomia algorítmica. A taxonomia de fontes de dano ao longo do ciclo de aprendizagem de máquina de Suresh e Gutttag (2021) reforça a necessidade de localizar em qual etapa cada distorção é introduzida. Bowyer et al. (2020) demonstram a fragilidade da suposta “criminalidade pela face”; Jacobs e Wallach (2021) mostram que mensuração e fairness dependem da validade do construto; e Raji et al. (2020, 2022) situam auditoria e alegações de funcionalidade ao longo do ciclo de vida do sistema. A documentação sistemática de datasets e modelos proposta por Gebru et al. (2021) e Mitchell et al. (2019), bem como a análise de viés de seleção de Roberts et al. (2017), reforça que origem, escopo e condições de uso pertencem à evidência científica.

Rótulos observáveis podem ser proxies frágeis para fenômenos latentes; Guerdan et al. (2023) descrevem fontes de viés do alvo e as hipóteses necessárias para tratar proxies como evidência. D'Amour et al. (2022) mostram que *pipelines* subespecificados podem manter desempenho semelhante e variar em comportamentos relevantes. Schoeffer, De-Arteaga e Elmer (2025) demonstram que escolhas não verificáveis na construção de rótulos podem produzir modelos divergentes, enquanto Coston (2026) propõe falsificar a validade discriminante quando um algoritmo pode prever melhor proxies impermissíveis que o resultado pretendido. Essas literaturas situam a contribuição desta monografia sem transformar a expressão “falácia da separabilidade endógena” em reivindicação de prioridade terminológica.

O problema permanece atual em modelos multimodais. Birhane et al. (2024) avaliaram 14 modelos visiolinguísticos e observaram associações racializadas com a classe “criminal”, cujo comportamento mudou com a escala do modelo e do conjunto de

treinamento. O resultado não equivale ao experimento desta monografia, mas reforça que rótulos morais podem emergir de escolhas de dados, classes e representação, exigindo auditoria de sua proveniência e significado.

Na biometria, a avaliação contínua do NIST destaca que diferenças demográficas de erro dependem do algoritmo, da tarefa e da qualidade da imagem (NIST, 2026). Resultados clássicos como os de Buolamwini e Gebru (2018) também mostram que desempenho agregado pode ocultar disparidades entre grupos. FairFace foi criado para estudar desequilíbrios de atributos em um domínio próprio e fornece categorias históricas de anotação, não uma ontologia biológica nem autoidentificação irrestrita (Kärkkäinen; Joo, 2021). Por isso, o braço externo é tratado como análise de sensibilidade de composição, sem transferência de rótulos ao corpus principal.

A novidade reivindicada por esta monografia não é a constatação isolada de que um rótulo derivado das próprias *features* pode produzir circularidade. Esse risco já é compatível com a literatura de validade de construto, proxies, vazamento, subespecificação e indeterminação de rótulos. A contribuição está em combinar, num mesmo estudo executável e auditável, **linhagem sociotécnica, identificabilidade, alvo endógeno, validação cruzada agrupada com ajuste estritamente no treino, estabilidade de agrupamento, controle sintético, perturbação de composição e limites raciais explícitos**. O Quadro 1 situa essa integração em relação aos eixos de trabalho anterior mobilizados no texto.

Quadro 1 — Trabalho anterior e contribuição integrada desta monografia

Eixo	Trabalho anterior mobilizado	Contribuição desta monografia
Validade de construto e proxies	A literatura distingue desempenho sobre um proxy de validade do construto pretendido (Jacobs; Wallach, 2021; Guerdan et al., 2023; Coston, 2026).	Formaliza o alvo endógeno e separa recuperabilidade interna, validade de construto e limites inferenciais externos.
Linhagem, seleção e auditoria	Proveniência, seleção e documentação condicionam o significado dos resultados (Roberts et al., 2017; Raji et al., 2020, 2022; Gebru et al., 2021).	Reconstrói a linhagem sociotécnica das listas de procurados e explicita o que é ou não identificável em cada estágio.
Subespecificação e rótulos	Configurações ou escolhas de rotulagem podem produzir comportamentos divergentes apesar de métricas semelhantes (D'Amour et al., 2022; Schoeffer; De-Arteaga; Elmer, 2025).	Mede estabilidade sob sementes, k , ordem, minilote e representação, com 611 execuções e comparações pareadas.
Separação entre ajuste e avaliação	<i>Sample splitting</i> e <i>cross-fitting</i> separam etapas de ajuste e avaliação em amostras complementares (Chernozhukov et al., 2018).	Usa validação cruzada agrupada com ajuste estritamente no treino e auditoria explícita de cada operação ajustável.

Eixo	Trabalho anterior mobilizado	Contribuição desta monografia
Circularidade demonstrável	A crítica à fisiognomia algorítmica e à “criminalidade pela face” mostra que separabilidade não basta para sustentar um construto moral (Bowyer et al., 2020; Birhane et al., 2024).	Acrescenta um controle sintético em que um alvo sem construto social externo atinge ROC-AUC = 1,000, isolando a possibilidade de separabilidade puramente endógena.
Composição e limites raciais	Auditorias biométricas mostram dependência de dados, tarefa e composição, e FairFace fornece categorias históricas para estudos de desequilíbrio (NIST, 2026; Kärkkäinen; Joo, 2021).	Perturba composição e amostragem em domínio externo, sem inferir raça no corpus principal, e explicita limites raciais e causais da interpretação.

Fonte: elaboração própria a partir da literatura discutida nesta seção. A originalidade reivindicada é a integração do protocolo e da evidência, não a prioridade terminológica da expressão “falácia da separabilidade endógena”.

2 MATERIAIS E MÉTODOS

2.1 Unidade de análise e estado preservado

A unidade observada é um registro público coletado, não uma ocorrência criminal nem, necessariamente, uma pessoa única. Foram considerados manifestos, imagens alinhadas, embeddings ArcFace de 512 dimensões, relatórios de pré-processamento, código e saídas da auditoria. O estado de código e documentação desta edição foram congelados na tag `paper-v1.1-final`, commit 6b81953. A tag fornece um ponto canônico para a edição definitiva, sem reescrever retroativamente a proveniência da corrida anterior nem provar equivalência byte a byte com sua árvore de trabalho modificada.

A documentação contemporânea foi usada para localizar implementação e artefatos da auditoria final, sem imputar retroativamente seus parâmetros ao *pipeline* histórico. Essa separação é essencial: agrupamento-alvo, validação cruzada agrupada com ajuste estritamente no treino, PCA-64 especificada, calibração, limiares, auditoria de `group_id` e desenho ampliado de estabilidade pertencem à reconstrução atual; regras históricas ausentes permanecem não recuperadas (Gusmão, 2026).

2.2 Framework de auditoria da separabilidade endógena

Seja X o dado observado, Z uma representação, Y um alvo produzido ou selecionado pelo *pipeline*, s um escore avaliado contra Y e C o construto externo alegado. As relações internas do *pipeline* são:

$$Z = f(X), \quad Y = h(Z), \quad s = g(Z) \quad (2.1)$$

$$\text{Sep}(s, Y) \not\approx \text{Valid}(Y, C) \quad (2.2)$$

Na equação (2.2), $\text{Sep}(s, Y)$ representa a separabilidade interna do escore em relação ao alvo endógeno; $\text{Valid}(Y, C)$ representa a validade de construto ou de critério, conforme o papel de C . ROC-AUC e PR-AUC respondem à primeira relação, mas não demonstram a segunda (Saito; Rehmsmeier, 2015). Validade externa é reservada à generalização para outras populações, contextos e processos de seleção; não é uma AUC contra um critério externo.

Proposição 1 — Separabilidade endógena sem validade de critério. Para todo $\varepsilon > 0$, existe um pipeline (f, h, g) tal que $AUC(g(Z), h(Z)) > 1 - \varepsilon$ e, para qualquer critério binário externo C independente de Z , $AUC(g(Z), C) = 0,5$ em esperança.

Prova por construção. Seja $Z = f(X)$ uma representação particionada por h e seja $Y = h(Z)$ o indicador de pertencimento à célula-alvo. Defina $g(Z)$ como a margem entre a distância à célula não alvo mais próxima e a distância à célula-alvo. Pela própria regra de atribuição, a margem é positiva para $Y = 1$ e negativa para $Y = 0$; portanto, todos os pares positivo–negativo são corretamente ordenados e $AUC(g(Z), Y) = 1 > 1 - \varepsilon$. Se $C \perp Z$, então $C \perp g(Z)$ e a probabilidade de um escore positivo superar um negativo em relação a C é $1/2$, ressalvados empates tratados pela definição usual da AUC. Logo, separabilidade interna não implica associação com esse critério. A independência $C \perp Z$ constrói um contraexemplo lógico; não afirma que criminalidade seja empiricamente independente de toda característica codificada em Z . $\square$

Corolário. O argumento permanece válido quando f , h , g e a calibração são ajustados somente no treino e avaliados em grupos fora da dobra: a separação correta elimina vazamento entre treino e teste, mas não cria dependência entre Z e um critério independente. A construção executável está em `<scripts/run_proposition_demo.py>`; seus resultados estruturados ficam em `<artifacts/proposition/proposition_results.csv>`.

Proposição 2 — Separabilidade não implica unicidade do alvo. Existem dois alvos endógenos $Y_1 = h_1(Z)$ e $Y_2 = h_2(Z)$, com escores $s_1 = g_1(Z)$ e $s_2 = g_2(Z)$, tais que $AUC(s_1, Y_1) = AUC(s_2, Y_2) = 1$ e $J(Y_1, Y_2) = 0$.

Prova por construção. Tome uma representação escalar Z com massa positiva em ambos os lados de zero. Defina $Y_1 = \mathbb{I}[Z > 0]$, $s_1 = Z$, $Y_2 = \mathbb{I}[Z < 0]$ e $s_2 = -Z$. Cada escore ordena perfeitamente os positivos de seu próprio alvo, logo ambas as AUCs são 1. Como os conjuntos $\{Z > 0\}$ e $\{Z < 0\}$ são disjuntos, seu Jaccard é 0. A proposição demonstra possibilidade, não inevitabilidade: a baixa estabilidade precisa ser estabelecida empiricamente para cada pipeline. $\square$

O protocolo operacional consiste em localizar a origem de Y ; separar ajuste, seleção e avaliação; executar controles que rompam a relação geométrica; perturbar sementes, hiperparâmetros, ordem e representação; e classificar como não identificável toda alegação externa sem variável, comparador ou denominador observável. O caso de ‘criminalidade facial’ funciona como demonstração construtiva dessa falha, mas o protocolo também se aplica a inferências de personalidade, empregabilidade, periculosidade, emoção ou orientação política.

2.3 Classes de identificabilidade

Cada alegação foi classificada antes da interpretação. “Identificável” designa uma grandeza para a qual unidade, variável e denominador são observáveis no estado preservado. “Diagnosticável” designa uma propriedade interna que pode ser testada sem representar o construto social de interesse. “Não identificável” designa um estimando para o qual faltam variáveis, comparadores, denominadores ou contrafactuais essenciais. “Parcialmente verificável” foi reservado a resultados existentes cujos números podem ser localizados, mas cujo procedimento completo não pode ser reconstruído independentemente.

Quadro 2 — Matriz de auditoria, evidência e identificabilidade


Alegação	Unidade/denominador	Evidência disponível	Classe
Fluxo técnico atual	Linha/estágio do manifesto	Manifesto final, hashes e relatórios	Identificável
Cobertura de extração	Embedding por registro	9.584 registros; 9.482 vetores válidos	Identificável
Relação 9.546↔9.584	Estados históricos distintos	Sem elo documental recuperado	Não identificável
Estabilidade computacional atual	Execuções/pares sob perturbação	611 execuções; comparações pareadas de ARI/Jaccard	Diagnosticável
Recuperação agrupada atual	Dobra por <code>group_id</code> provável	5 dobras; métricas e auditoria de ajuste	Diagnosticável
ROC/PR históricos	Dobra do estado preservado	0,930/0,479 reportados; protocolo histórico incompleto	Parcialmente verificável
Influência por fonte	Fonte e denominadores institucionais	Fonte analítica não recuperada	Não identificável
Composição/seletividade racial do corpus	Raça/cor documentada e denominadores comparáveis	Rótulos raciais validados e denominadores ausentes	Não identificável
Equidade biométrica por grupo	Pares genuínos/impostores, grupos e protocolo	Identidade confirmada e protocolo biométrico ausentes	Não identificável

Fonte: elaboração própria. “Diagnosticável” descreve a operação interna do pipeline, não sua validade externa.

2.4 Cadeia sociotécnica de seleção e status da evidência

A inclusão final foi representada como condicionamento em $S = 1$. O símbolo resume, para fins analíticos, transições distintas: decisão institucional de localizar e divulgar, permanência na página, disponibilidade de fotografia, coleta, padronização, detecção facial e extração válida. O modelo não estima efeitos causais; ele organiza mecanismos de seleção que limitam o universo observável (Elwert; Winship, 2014; Hernán; Hernández-Díaz; Robins, 2004).

Figura 1 — Cadeia sociotécnica, endogeneidade do alvo e limites inferenciais.



Fonte: elaboração própria. O diagrama distingue seleção/observabilidade, geometria interna e o vínculo externo que precisaria ser demonstrado.

Quadro 3 — Transições de seleção e observabilidade no estado auditado

Transição	Mecanismo de inclusão/exclusão	Evidência por registro	Status
Decisão institucional	Investigação, jurisdição, pedido e prioridade	Não disponível	Não observável por registro
Publicidade e vigência	Publicação, permanência, retirada ou localização	Datas e motivo não confiáveis	Não identificável temporalmente
Coleta	Página acessível e captura técnica	Contagem agregada herdada	Reconciliação documental
Padronização	Formato, download e processamento	Contagens agregadas herdadas	Reconciliação documental
Manifesto analítico	Registro admitido no conjunto final	9.584 linhas reproduzidas	Reproduzido/verificado
Extração de embedding	Face detectável e vetor válido	9.482 vetores; 102 falhas	Reproduzido/verificado

Fonte: elaboração própria a partir dos artefatos e das limitações de proveniência declaradas no estado preservado.

2.5 Proveniência de fonte e análises excluídas

A variável de fonte permanece não recuperada no manifesto analítico que sustenta a avaliação final. Assim, enriquecimento por fonte, previsibilidade de fonte, balanceamento, leave-one-source-out, efeito causal de fonte e composição temporal não são estimados. A auditoria também não reconstrói datas institucionais de inclusão/remoção. Essas ausências são preservadas como limites de proveniência, e não preenchidas por nomes de arquivos ou inferência ad hoc.

Os resultados são classificados pela sua relação com a evidência. As contagens 11.724, 9.764 e 9.546 são histórico preservado documentado; 9.584 e 9.482 foram reproduzidas no estado atual; a ligação histórica entre 9.546 e 9.584 permanece não recuperada. As métricas ROC-AUC 0,930 e PR-AUC 0,479 da edição anterior continuam apenas como resultados históricos reportados. Já a validação cruzada agrupada com ajuste estritamente no treino, os limiares/calibração, PCA-64, `group_id` e a estabilidade ampliada são reconstruções ou análises novas da auditoria final, sem atribuição retroativa ao *pipeline* histórico.

2.6 Análise de estabilidade computacional

A auditoria final separa três tipos de instabilidade: estocástica, operacional e de representação. O desenho estocástico combina 100 sementes explícitas com $k = 32, 48, 64, 80, 96$ e 128 , totalizando 600 execuções com ordem original, representação L2 e `batch_size` primário. A instabilidade operacional é examinada por quatro ordens (original, reversa, embaralhamento com semente e índice ordenado por hash) e por cinco `batch_size` (256, 512, 1.024, 2.048 e 4.096). A instabilidade de representação compara `original_l2` e PCA-64. O desenho completo contém 611 execuções e foi concluído integralmente. A leitura da estabilidade de agrupamentos segue a tradição de Ben-Hur, Elisseeff e Guyon (2002), Hubert e Arabie (1985) e von Luxburg (2010).

O agrupamento reconstruído usa `MiniBatchKMeans` (Pedregosa et al., 2011). A configuração primária fixa $k = 64$, `batch_size = 1.024`, `max_iter = 100` e `n_init = 3`; o primeiro valor da lista explícita de sementes atua como semente primária nas análises operacionais e de representação. O agrupamento-alvo é o maior agrupamento. Para a partição completa usa-se ARI; para o conjunto-alvo, Jaccard. A análise final calcula também tamanho e prevalência do alvo. Em vez de comparar todas as soluções contra uma única referência, as partições de cada grupo comparável são avaliadas em pares e resumidas por distribuição; a execução produziu 60.045 comparações pareadas, evitando que a conclusão dependa de uma referência arbitrária. Essas comparações são descritivas e não são tratadas como unidades experimentais independentes; a incerteza inferencial é estimada no nível de grupo, dobra ou replicação, conforme o desenho.

ARI é interpretado como concordância de partições corrigida pelo acaso e Jaccard como sobreposição do conjunto-alvo, $J(A, B) = |A \cap B| / |A \cup B|$ (Hubert; Arabie, 1985; von Luxburg, 2010). Essas métricas diagnosticam dependência computacional

dentro da região de configurações examinada; não validam uma partição substantiva, identidade, categoria social ou propriedade jurídica. A edição anterior continha oito contrastes contra uma referência com ARI de 0,072 a 0,113 e Jaccard de 0 a 0,124; esses valores são mantidos apenas como subconjunto documentado da reconstrução anterior, não como resumo estatístico da corrida final ampliada.

PCA-64 é uma reconstrução atual explicitamente especificada, não uma configuração histórica recuperada: 64 componentes, `solver randomized`, `random_state = 20260727`, `centering = true`, `whitening = false`, normalização L2 antes e depois da transformação. Na avaliação por dobra, a PCA — quando utilizada — é ajustada exclusivamente no treino e aplicada ao teste; na análise de sensibilidade de representação sobre todos os registros, seu escopo é declarado separadamente. A especificação e a variância explicada são registradas em `<pca_specification.json>`. Nenhum desses parâmetros é atribuído ao procedimento histórico ausente.

2.7 Validação cruzada agrupada e contrato de reprodução

A avaliação principal é descrita neste trabalho como **validação cruzada agrupada com ajuste estritamente no treino**. A reconstrução final usa `GroupKFold` com cinco dobras definidas por `group_id` de duplicidade provável. Em cada dobra, a representação ajustável, o `MiniBatchKMeans`, a escolha do agrupamento-alvo, o centroide, a calibração logística e o limiar são ajustados exclusivamente no treino. O conjunto de teste é transformado sem reajuste; o modelo de agrupamento treinado prediz o rótulo de agrupamento do teste e o alvo binário é definido por pertencimento ao agrupamento-alvo escolhido no treino. O escore bruto é a similaridade com o centroide-alvo; quando há duas classes no treino, uma regressão logística treinada apenas no treino produz o escore probabilístico. O procedimento compartilha com o *cross-fitting* o princípio de *sample splitting* — ajuste em amostras complementares e avaliação fora da amostra usada no ajuste — discutido por Chernozhukov et al. (2018), mas o termo *cross-fitting* não é usado aqui como denominação principal nem implica inferência semiparamétrica ou conclusões causais.

Algoritmo 1 — Protocolo executado de validação cruzada agrupada com ajuste estritamente no treino

1. Particionar os registros com `GroupKFold` por `group_id` provável, sem grupo compartilhado entre treino e teste.
2. Ajustar qualquer representação aprendida somente no treino e apenas transformar o teste.
3. Ajustar `MiniBatchKMeans` somente no treino.
4. Selecionar, somente no treino, o maior agrupamento como alvo e construir `y_train`.
5. Calcular o centroide do alvo no treino e pontuar treino e teste por similaridade com esse centroide.
6. Produzir `y_test` por `model.predict(test)` e pertencimento ao rótulo do agrupamento-alvo selecionado no treino.
7. Ajustar a calibração logística somente no treino quando houver duas classes.

8. Selecionar o limiar somente no treino pelo máximo F1 da curva precisão–revocação.
9. Avaliar o teste uma única vez e registrar prevalência, grupos, limiar, calibração, métricas e hash do estado de treino.
10. Auditar cada etapa ajustada e falhar se houver índice de teste ou registro fora do treino.

A auditoria de ajuste registrou 25 eventos em cinco dobras e encontrou zero sobreposição com o teste e zero ajustes fora do treino, em linha com o princípio de prevenção de vazamento entre ajuste e avaliação discutido por Kaufman et al. (2012). Isso fortalece a validade interna da reconstrução atual contra vazamento direto treino/teste. Não elimina, porém, a endogeneidade conceitual: y_{train} e y_{test} são definidos pelo próprio agrupamento treinado e projetado no espaço de embeddings, portanto as métricas medem recuperação de um alvo sintético reconstruído, não correspondência com um critério externo.

Limiar e calibração estão agora metodologicamente especificados para a reconstrução atual. A ROC-AUC é lida como medida de ordenação e não como validação de construto, interpretação compatível com a discussão de Fawcett (2006). A calibração é logística e ajustada somente no treino; por isso o Brier pode ser interpretado como erro quadrático probabilístico em relação ao alvo sintético desta reconstrução. Essa interpretação não é transferível para probabilidade de criminalidade, culpa, identidade ou qualquer atributo humano. Os números históricos antigos continuam separados: o protocolo que produziu ROC-AUC 0,930 e PR-AUC 0,479 não foi integralmente recuperado e não deve ser presumido idêntico ao protocolo atual.

2.7.1 Construção e limites do `group_id`

Na reconstrução atual, `group_id` é um agrupamento conservador de duplicidade provável baseado em embeddings L2-normalizados e similaridade cosseno. Pares com similaridade pelo menos 0,999 são conectados e componentes são formados por *union-find*; identificadores públicos dos grupos são pseudonimizados. Foram obtidos 9.422 grupos prováveis entre 9.482 registros, dos quais 59 são não unitários; 1,255% dos registros pertencem a grupos com mais de um registro. O limiar primário 0,999 é uma escolha metodológica da auditoria atual, não uma identidade biométrica validada nem um parâmetro histórico recuperado.

A separação agrupada garante que nenhum `group_id` provável atravesse treino e teste. Isso controla duplicidades conforme a heurística construída, mas não prova que a mesma pessoa não possa ocorrer em grupos diferentes. A amostra

pseudonimizada de pares próximos ao limiar foi submetida à revisão humana e nenhum erro de agrupamento foi identificado nos pares revisados. Essa verificação sustenta a adequação operacional da heurística no material inspecionado, mas não converte os grupos em identidades biométricas confirmadas nem demonstra que uma mesma pessoa não possa ocorrer em grupos diferentes.

A análise de sensibilidade executada reconstruiu os grupos nos limiares 0,995, 0,997, 0,999 e 0,9995. O número de grupos variou pouco (9.416–9.422) e a ROC-AUC permaneceu entre 0,979 e 0,984, mas a identidade do alvo foi sensível: tomando 0,999 como referência, o Jaccard foi 0,062 em 0,995 e 0,017 em 0,997; 0,999 e 0,9995 produziram a mesma solução. Assim, estabilidade da métrica agregada não implicou estabilidade dos registros classificados como alvo. Os resultados completos estão em <artifacts/groupid_sensitivity/sensitivity_curve.csv>.

2.8 Níveis de verificabilidade computacional

Quadro 4 — Escada de verificabilidade computacional

Nível	Critério	Situação neste estudo
Rastreabilidade	Localizar código, entradas, configuração e outputs	Alta para a auditoria final: manifesto, hashes, run_id e 20 outputs registrados; histórica incompleta
Reexecução	Executar o protocolo atual no ambiente declarado	Realizada na configuração final; 611/611 execuções de estabilidade e 5 dobras agrupadas
Reprodução numérica atual	Obter novamente resultados do protocolo reconstruído	9.584 e 9.482 reproduzidos; métricas atuais e outputs estruturados registrados
Reprodução histórica	Reconstituir integralmente o procedimento antigo	Parcial: ROC/PR antigos e regras históricas centrais permanecem apenas preservados/não recuperados
Replicação independente	Nova equipe/dados/protocolo externo	Não realizada

Fonte: elaboração própria. A escada separa localização de artefatos, reexecução, reprodução numérica e replicação externa.

2.9 Experimento externo de composição demográfica

Como o corpus principal não possui raça/cor documentada nem vínculo verificável com bases demográficas externas, a sensibilidade à composição foi examinada em braço independente com FairFace (Kärkkäinen; Joo, 2021). Foram

usadas apenas as sete categorias fornecidas pela base; nenhuma categoria foi inferida visualmente ou transferida ao *pipeline* de procurados. Cada cenário contém 36.456 registros sem reposição. As proporções foram controladas, mas a identidade específica das imagens também varia entre cenários; portanto, o desenho não isola o efeito da proporção demográfica do efeito da amostragem de registros. A composição de entrada dos quatro cenários é apresentada no Quadro 5.

Quadro 5 — Composição demográfica de entrada dos cenários A a D (FairFace)

Categoria	A (proporcional)	B (balanceado)	C (ME reduzido)	D (ME aumentado)
Black	5.145 (14,1%)	5.208 (14,3%)	5.642 (15,5%)	4.340 (11,9%)
East Asian	5.163 (14,2%)	5.208 (14,3%)	5.642 (15,5%)	4.340 (11,9%)
Indian	5.163 (14,2%)	5.208 (14,3%)	5.642 (15,5%)	4.340 (11,9%)
Latino_Hispanic	5.594 (15,3%)	5.208 (14,3%)	5.642 (15,5%)	4.340 (11,9%)
Middle Eastern	3.890 (10,7%)	5.208 (14,3%)	2.604 (7,1%)	10.416 (28,6%)
Southeast Asian	4.556 (12,5%)	5.208 (14,3%)	5.642 (15,5%)	4.340 (11,9%)
White	6.945 (19,1%)	5.208 (14,3%)	5.642 (15,5%)	4.340 (11,9%)
Total	36.456	36.456	36.456	36.456

Fonte: quotas calculadas pela rotina `scenario_quotas` sobre o catálogo FairFace. A = alocação proporcional ao catálogo; B = equipartição entre as sete categorias; C = Middle Eastern reduzido a metade da equipartição, restantes redistribuídos; D = Middle Eastern duplicado em relação à equipartição, restantes redistribuídos. ME = Middle Eastern. Categorias são rótulos históricos fornecidos pelo FairFace, não autoidentificação.

A liberação `margin025`, recortada e alinhada upstream com `dlib.get_face_chip()`, foi fornecida diretamente ao reconhecedor do pacote `InsightFace buffalo_l`. A implementação usa `InsightFace 1.0.1`, `ONNX Runtime 1.18.1`, leitura RGB com conversão para BGR, normalização de pixels e redimensionamento executados pelo reconhecedor, embedding de 512 dimensões e normalização L2 posterior. O arquivo de reconhecimento disponível no ambiente é `<w600k_r50.onnx>`, mas seu hash não foi incorporado ao manifesto da corrida FairFace; por isso, o SHA-256 observado posteriormente não é atribuído retroativamente à execução. `MiniBatchKMeans`, `n_init = 3`, `batch_size = 1.024`, `max_iter = 100`, regra do maior agrupamento, escore cosseno e avaliação foram mantidos constantes.

As comparações entre cenários usam apenas a interseção dos identificadores presentes em ambos. Os limites $ARI < 0,90$, $Jaccard < 0,80$, $|\Delta \text{prevalência}| \geq 0,02$ e $|\Delta \text{AUC}| \geq 0,03$ foram pré-declarados como heurísticas descritivas para organizar a leitura, não como limiares de significância ou relevância substantiva validados externamente. A inferência principal usa distribuições e tamanhos de efeito contínuos.

O desenho A–D é mantido como análise de sensibilidade exploratória. A escolha de Middle Eastern como categoria perturbada não sustenta inferência específica sobre essa categoria nem generaliza para as demais; ela define apenas o contraste local executado. Isolar efeitos de composição exigiria perturbar simetricamente as sete categorias em replicações pareadas e estimar incerteza na hierarquia replicação $\times$ cenário $\times$ semente $\times k$. Como esse desenho confirmatório não integra a evidência desta versão, nenhuma decomposição causal ou inferencial é atribuída às comparações atuais.

2.9.1 Escopo da regra de definição do alvo

O resultado empírico principal usa exclusivamente a regra pré-especificada do maior agrupamento. Regras alternativas — compacidade, separação, centralidade, outlier ou controle aleatório — definem outros estimandos e não são combinadas com a AUC principal. A Proposição 2 demonstra que alvos endógenos incompatíveis podem ser individualmente separáveis, mas não substitui uma ablação empírica. Portanto, esta versão restringe sua conclusão de estabilidade à regra executada e não afirma quantas definições alternativas superariam qualquer limiar de AUC.

3 RESULTADOS

3.1 Fluxo de registros e cobertura técnica

A corrida final reproduz 9.584 linhas no manifesto analítico e 9.482 embeddings válidos de 512 dimensões. As contagens 11.724, 9.764 e 9.546 foram preservadas como artefatos históricos documentados, mas não reclassificadas como reproduzidas. A relação entre o estado histórico de 9.546 e o manifesto de 9.584 continua sem elo documental recuperado; por isso não se calcula taxa de retenção entre esses estados nem se força uma única coorte retrospectiva.

Tabela 1 — Quantidades por estágio e status da evidência

Estágio/contagem	n	Status da evidência
Coleta bruta histórica	11.724	Histórico preservado/documentado
Entrada na padronização histórica	9.764	Histórico preservado/documentado
Processamento bem-sucedido histórico	9.546	Histórico preservado/documentado
Manifesto analítico atual	9.584	Reproduzido/verificado no artefato atual
Embeddings válidos atuais	9.482	Reproduzido/verificado no artefato atual

Fonte: auditoria de linhagem da execução final. As cinco contagens pertencem a estados de evidência distintos; a relação 9.546↔9.584 permanece não recuperada e não é usada para calcular retenção.

3.2 Lacunas de proveniência e estado histórico

A proveniência por fonte e por tempo permanece não identificável. O manifesto público da auditoria final usa source = unresolved para os registros pseudonimizados; não há denominadores institucionais nem painel confiável de entradas/remoções. Consequentemente, a execução final não estima influência institucional, enriquecimento por fonte, composição temporal ou seletividade racial. A impressão visual de maior ou menor presença de qualquer grupo nas páginas coletadas não é tratada como dado racial: sem raça/cor documentada por registro, transformá-la em porcentagem exigiria uma classificação visual que o próprio estudo considera metodologicamente inadequada e eticamente arriscada.

A principal melhora de linhagem é classificatória, não retrospectiva: a auditoria passa a registrar explicitamente o que é histórico preservado, reproduzido, reconstruído, novo ou não recuperado. Essa distinção impede que números localizados em relatórios antigos sejam tratados como se tivessem sido reobtidos pelo

protocolo atual.

3.3 Estabilidade computacional da partição

Tabela 2 — Estabilidade estocástica por k: medianas, IQR e intervalos P05–P95.

k	ARI mediana (IQR)	ARI P05–P95	Jaccard mediana (IQR)	Jaccard P05–P95	Prevalência mediana (IQR)
32	0.113 (0.104–0.123)	0.095–0.142	0.001 (0.000–0.020)	0.000–0.437	0.052 (0.049–0.055)
48	0.091 (0.084–0.099)	0.077–0.112	0.001 (0.000–0.051)	0.000–0.166	0.044 (0.041–0.047)
64	0.085 (0.078–0.092)	0.071–0.104	0.004 (0.000–0.047)	0.000–0.126	0.041 (0.038–0.044)
80	0.077 (0.072–0.083)	0.066–0.094	0.038 (0.004–0.066)	0.000–0.110	0.042 (0.038–0.047)
96	0.073 (0.069–0.079)	0.063–0.089	0.042 (0.013–0.073)	0.000–0.123	0.043 (0.040–0.048)
128	0.070 (0.065–0.075)	0.060–0.085	0.051 (0.027–0.079)	0.000–0.123	0.047 (0.041–0.051)

Fonte: <stability_summary.csv>. Para ARI e Jaccard, $n = 4.950$ pares distintos por k ; para prevalência, $n = 100$ execuções por k . IQR = $Q1-Q3$.

A corrida final torna visível o resultado das 60.045 comparações. Entre sementes, a mediana do ARI diminuiu de 0,113 em $k = 32$ para 0,070 em $k = 128$. A mediana do Jaccard do conjunto-alvo permaneceu entre 0,001 e 0,051; em $k = 64$ foi 0,004 (IQR 0,000–0,047; P05–P95 0,000–0,126). Esses valores mostram baixa concordância tanto da partição completa quanto da identidade do maior agrupamento na região examinada.

A sensibilidade não se restringiu à semente. Em $k = 64$, mudanças de ordem produziram ARI mediano 0,100 e Jaccard 0,000; mudanças de `batch_size`, ARI 0,085 e Jaccard 0,003; o contraste original $L2 \times PCA-64$ resultou em ARI 0,090 e Jaccard 0,000. A prevalência do alvo também variou: entre `batch_size`, a mediana foi 0,040 e o intervalo observado 0,028–0,125. Como o desenho cobre uma grade finita, os resultados sustentam instabilidade condicionada às perturbações executadas, não uma afirmação universal sobre todo algoritmo de agrupamento.

3.4 Validação cruzada agrupada: histórico preservado e reconstrução atual

Dois conjuntos de resultados devem ser mantidos separados. O estado histórico preserva ROC-AUC média de 0,930 e PR-AUC de 0,479 em cinco dobras, mas sua

regra histórica completa de geração do alvo, prevalências, limiares e calibração não foi recuperada; esses números permanecem parcialmente verificáveis. A auditoria final executou um protocolo novo e explícito de validação cruzada agrupada com ajuste estritamente no treino, com cinco dobras, `group_id` provável, calibração logística e limiar selecionado no treino. As métricas atuais medem exclusivamente recuperação interna do alvo sintético reconstruído.

Tabela 3 — Resultados históricos preservados e reconstrução agrupada atual

Métrica	Histórico preservado	Reconstrução atual final
ROC-AUC	0,930 (média reportada; protocolo histórico incompleto)	0,896
PR-AUC	0,479 (média reportada; baseline histórica não auditável)	0,348
Baseline PR-AUC	Não recuperada	0,054
Brier	Não interpretado por calibração histórica não recuperada	0,043
Balanced accuracy	Não usada como evidência principal	0,650
F1	Não usada como evidência principal	0,338
Precisão	Não usada como evidência principal	0,370
Revocação	Não usada como evidência principal	0,333

Fonte: histórico preservado na edição anterior e <FINAL_REPRODUCTION_REPORT/cross_fitted_metrics.csv> para a reconstrução final. Os resultados atuais não são apresentados como reprodução do procedimento histórico.

Na reconstrução atual, a ROC-AUC média foi 0,896, com variação entre dobras de 0,882 a 0,904 e IC bootstrap de 95% de 0,884 a 0,908. A PR-AUC média foi 0,348 (IC 95%: 0,315–0,394), frente a baseline média 0,054, e o Brier médio foi 0,043 (IC 95%: 0,040–0,047). As predições OOF individuais foram preservadas em <artifacts/primary_oof_confirmatory/tables/oof_predictions.csv>. Os 2.000 reamostragens preservam grupos inteiros dentro de cada dobra e calculam a média das métricas de dobra; registros ou pares reutilizados não são tratados como replicações independentes. Esses números quantificam recuperabilidade interna do alvo sintético, não desempenho para criminalidade, culpa, raça/cor ou outro atributo externo.

A auditoria registrou 25 eventos de ajuste em cinco dobras, todos com `test_overlap = 0` e `outside_train = 0`; `group_id` também não atravessou as divisões. Essa evidência sustenta a ausência de vazamento direto conforme a unidade de bloqueio construída. Como `group_id` representa apenas duplicidade provável, não se

afirma ausência absoluta de uma mesma pessoa em grupos diferentes.


3.5 Resultado Empírico 1: paradoxo performance–estabilidade

Este é o resultado central da monografia. O controle sintético passou nas três demonstrações pré-definidas e resume o argumento em seu caso mais simples: um agrupamento gerou um alvo sem qualquer variável social externa; um escore derivado da mesma geometria recuperou esse alvo com ROC-AUC = 1,000; e mudar $k = 3$ para $k = 4$ trocou completamente o conjunto-alvo (Jaccard = 0,000). Em linguagem direta: foi possível obter “desempenho perfeito” sobre um rótulo que não significava nada fora do próprio experimento. O controle não representa pessoas e não prova um efeito no corpus principal; ele demonstra que separabilidade, por si só, não é validade.

No corpus principal, os dois diagnósticos apontam uma tensão relevante sem formar um par por especificação individual. A ROC-AUC de 0,896 vem da validação agrupada da configuração primária; o Jaccard mediano de 0,004 vem da distribuição de soluções entre sementes em $k = 64$. A Proposição 1 demonstra que separabilidade interna pode ocorrer sem validade de critério; a Proposição 2 demonstra que alvos incompatíveis podem ser individualmente separáveis. A baixa estabilidade observada continua sendo uma propriedade empírica adicional deste pipeline, não consequência necessária da Proposição 1. A Figura 2 apresenta os diagnósticos lado a lado.

Resultado Empírico 1. A configuração primária alcançou ROC-AUC média de 0,896 (IC bootstrap de 95%: 0,884–0,908). Separadamente, as soluções entre sementes em $k = 64$ apresentaram Jaccard mediano do alvo de 0,004 (IQR 0,000–0,047). O primeiro resultado mostra recuperabilidade interna; o segundo, baixa estabilidade da identidade do alvo na grade examinada. A coexistência é empiricamente importante, mas não prova que todo alvo endógeno seja instável.

Figura 2 — Paradoxo separabilidade–estabilidade na reconstrução final.



Fonte: elaboração própria a partir de <cross_fitted_metrics.csv> e <stability_summary.csv>. Os painéis resumem desenhos distintos e não representam pares AUC–Jaccard por especificação individual.

3.6 Experimento externo: composição demográfica e estrutura do *pipeline*

O braço externo acrescenta uma resposta importante à questão étnico-demográfica: perturbações de composição e amostragem estiveram associadas a mudanças substanciais no padrão que o algoritmo encontra. Em $k = 64$, os cenários B, C e D apresentaram, contra A, ARI mediano de 0,182, 0,199 e 0,189 e Jaccard mediano do alvo próximo de 0,001. Isso significa que as partições e, sobretudo, a identidade do maior agrupamento apresentaram diferenças materiais em relação ao cenário A. O experimento, porém, também muda quais imagens foram amostradas e ocorre sobre forte instabilidade entre sementes; portanto, o desenho não isola o efeito da proporção demográfica do efeito da amostragem de registros.

Tabela 4 — Resultados do experimento externo de composição demográfica em $k = 64$

Cenário	Prevalência do alvo	ARI vs. A	Jaccard do alvo vs. A	ROC-AUC	PR-AUC
A	0,025	—	—	0,908	0,448
B	0,026	0,182	0,001	0,903	0,440
C	0,027	0,199	0,001	0,893	0,400
D	0,025	0,189	0,001	0,910	0,466

Fonte: DEMOGRAPHIC_COMPOSITION_EXPERIMENT e tabelas estruturadas da execução. Categorias demográficas permanecem restritas ao FairFace e não são transferidas ao corpus principal.

O resultado mais relevante é o contraste entre “desempenho” e “quem compõe o alvo”. A prevalência mediana do maior agrupamento ficou entre 0,025 e 0,027 e a ROC-AUC entre 0,893 e 0,910 — variações pequenas — enquanto a estrutura interna mudou fortemente. A PR-AUC apresentou mudança relevante apenas no cenário C, caindo de 0,448 para 0,400 ($\Delta = -0,048$). Assim, o sistema pode conservar uma aparência de desempenho estável e, ao mesmo tempo, estar chamando de “alvo” um conjunto substancialmente diferente. Para uma auditoria de viés, essa distinção é crucial: uma métrica agregada semelhante não significa que o modelo esteja tratando a mesma população da mesma forma.

Há, contudo, um segundo efeito que impede conclusões simplistas: o próprio agrupamento é muito sensível à semente. Em $k = 64$, o ARI mediano entre sementes variou de 0,186 a 0,198 e o Jaccard mediano do alvo de 0,000 a 0,015 nos quatro cenários. Portanto, não é correto dizer que “a composição demográfica causou” toda a mudança observada. O resultado defensável é mais preciso: perturbações

de composição, amostragem e configuração do algoritmo estiveram associadas a diferenças no padrão encontrado, enquanto algumas métricas de recuperação interna continuaram altas. É exatamente esse tipo de contingência que torna perigoso transformar um cluster em uma categoria humana substantiva.




Figura 3 — Composição média do agrupamento-alvo por categoria fornecida pelo FairFace nos cenários A a D.

Fonte: elaboração própria a partir das tabelas estruturadas da execução. As proporções descrevem somente o agrupamento sintético deste benchmark; não representam criminalidade, risco ou propensão de qualquer grupo.

A Figura 3 reforça que não existe, neste experimento, um “perfil étnico criminal” descoberto pela máquina. A composição do agrupamento-alvo variou entre os cenários de amostragem e entre execuções, em associação com um alvo que também apresentou baixa estabilidade. A categoria “Middle Eastern”, por exemplo, representou em média 14,4% do alvo em A, 24,7% em B, 12,6% em C e 31,8% em D. Esses valores não são taxas de crime, risco, culpa nem erro biométrico; são proporções condicionadas a um agrupamento sintético e instável. Na grade de k, a prevalência mediana do maior agrupamento variou aproximadamente de 0,017 a 0,048 em todos os cenários. No desenho executado, essas diferenças estiveram associadas às perturbações de composição, amostragem e configuração, sem identificar um efeito causal demográfico.




Figura 4 — Estabilidade entre sementes no experimento externo, em $k = 64$.

Fonte: elaboração própria a partir de <seed_stability.csv>. ARI resume a concordância da partição; Jaccard do alvo, a sobreposição do maior agrupamento entre execuções.

Os rótulos do FairFace são categorias históricas fornecidas pelo próprio dataset, não autoidentificação nem verdade biológica. Nenhuma delas é transferida para as pessoas das listas de procurados. O experimento também não estabelece que um grupo seja mais ou menos “criminoso”. Sua função é mostrar uma dependência empírica: a estrutura apresentada pelo algoritmo como padrão variou conforme a composição e a amostragem observadas no desenho executado, sem que isso identifique um efeito causal demográfico. Quando essa estrutura recebe um nome moral — “criminoso”, “perigoso”, “confiável” — a matemática pode ocultar, em vez de eliminar, o viés de seleção que veio antes dela.

4 DISCUSSÃO

4.1 Uma AUC alta não mede “criminalidade”

A ROC-AUC média de 0,896 é um resultado computacional forte, mas responde a uma pergunta estreita: o pipeline consegue recuperar, fora da dobra de treino, o alvo sintético construído a partir da própria geometria? Sim. Isso não equivale a perguntar se o rosto contém informação sobre criminalidade. Para essa segunda pergunta, o estudo não possui sequer uma variável observada de “criminalidade facial” contra a qual validar o modelo.

Esse ponto é central para a leitura leiga e técnica. Separabilidade mede se a regra construída pode ser reconhecida; estabilidade mede se essa regra continua parecida quando o pipeline é perturbado; validade de construto exige evidência independente de que o rótulo representa o conceito que recebe seu nome; validade externa exige uma população e um processo de seleção definidos. Confundir essas etapas transforma “o algoritmo reconhece seu próprio padrão” em “o algoritmo descobriu algo sobre pessoas”.

4.2 Como um viés ganha aparência matemática: a falácia da separabilidade endógena

A falácia da separabilidade endógena ocorre quando um sistema cria Y a partir da mesma representação que depois usa para prever Y e o pesquisador interpreta esse sucesso como evidência de um fenômeno externo C . Neste estudo, agrupamento, escolha do maior cluster, centroide, escore, calibração e rótulo de teste permanecem ligados à mesma geometria facial. O controle de vazamento é necessário e foi fortalecido, mas ele resolve apenas um problema técnico: não cria, por si só, a ponte entre distância facial e criminalidade, caráter, raça ou periculosidade. A crítica se conecta à literatura de validade de construto, rótulos-proxy, subespecificação, indeterminação de rótulos e validade discriminante (Guerdan et al., 2023; D'Amour et al., 2022; Schoeffer; De-Arteaga; Elmer, 2025; Coston, 2026).

Por isso, os resultados históricos e atuais devem permanecer separados. O antigo ROC-AUC 0,930 e PR-AUC 0,479 pertencem a uma execução cujo contrato completo não foi recuperado. Os atuais 0,896 e 0,348 pertencem a um protocolo reconstruído, auditável e mais restritivo quanto ao vazamento. A diferença entre esses números não revela uma propriedade do rosto; revela que regras computacionais diferentes produzem métricas diferentes.

4.3 Criminalidade não é atributo facial: validade de construto e fisiognomia algorítmica

Aparência facial, identidade, raça/cor, condição jurídica e criminalidade são grandezas diferentes. ArcFace foi desenvolvido para discriminação de identidade em protocolos biométricos; transformar seus vetores em clusters não converte distância facial em caráter, culpa ou propensão criminal (Deng et al., 2019; Jacobs; Wallach, 2021). Estudos críticos sobre “criminality from face” mostram que classificadores aparentemente eficazes podem explorar composição da base, condições de captura, estilo fotográfico e outros atalhos experimentais. Quando um sistema dá nome moral a esses atalhos, aproxima-se da fisiognomia algorítmica: números rigorosamente calculados aplicados a um construto que não foi validado (Bowyer et al., 2020).

A expressão “criminalidade facial” é mantida, portanto, como provocação crítica e não como hipótese substantiva. A saída observável do pipeline é similaridade em relação a um corpus selecionado e a um alvo construído. Não existe base nesta monografia para converter essa proximidade em probabilidade de crime, “tendência criminal”, periculosidade ou pertencimento racial. O experimento é relevante justamente porque mostra como uma interpretação preconceituosa pode adquirir aparência quantitativa sem ganhar validade científica.

4.4 Estabilidade computacional

As distribuições completas tornam a instabilidade um resultado, e não apenas um item de protocolo. ARI e Jaccard baixos aparecem em sementes, ordem, `batch_size` e representação, enquanto a prevalência varia de modo diferente. A escolha de `k` também altera a prevalência do maior agrupamento e a concordância das partições. Logo, semente, `k`, ordem, minilote, representação e regra de seleção do alvo devem ser tratados como componentes da evidência, não detalhes neutros de implementação (von Luxburg, 2010).

Os resultados permanecem condicionados à grade executada e ao MiniBatchKMeans. Eles não identificam uma partição verdadeira, mas rejeitam a apresentação de uma única solução como estrutura inevitável dos dados. Uma auditoria completa deve reportar distribuições, tamanho e prevalência do alvo, além das métricas de separabilidade.

4.5 Raça e seleção: o que o experimento mostra — e o que não mostra

A dimensão racial não é um apêndice deste problema. Ela está na própria pergunta sobre quem entra na base e quais decisões institucionais antecedem o algoritmo. Investigação, prioridade policial, jurisdição, decisão de divulgação, permanência da página, disponibilidade de fotografia, coleta e processamento filtram o corpus antes que o modelo veja qualquer rosto. Em um sistema penal no qual desigualdades raciais são documentadas, tratar essa seleção como se fosse uma amostra neutra seria um erro metodológico e social.

Ao mesmo tempo, a motivação racial precisa de um limite metodológico claro. A impressão visual de que pessoas percebidas como negras, brancas ou pertencentes a outras categorias aparecem em maior ou menor número nas listas pode gerar uma hipótese, mas não é uma estatística. O corpus principal não possui raça/cor declarada por registro, proveniência de fonte suficientemente recuperada nem denominadores comparáveis. Portanto, esta monografia não afirma que pessoas negras sejam mais ou menos representadas nas listas e não usa um classificador para “descobrir” raça pela face. Fazer isso repetiria o mesmo erro que o trabalho critica: transformar aparência em atributo social supostamente objetivo.

O braço FairFace foi incluído para responder a uma pergunta diferente e mais controlável: perturbações de composição e amostragem demográfica estão associadas a mudanças no padrão interno do pipeline mesmo quando a métrica agregada parece estável? Os resultados dizem que sim para o desenho executado: as partições e a identidade do alvo apresentaram mudanças materiais, enquanto prevalência e ROC-AUC variaram pouco. Isso não prova racismo nas listas de procurados e não identifica um efeito causal de raça. Demonstra, porém, uma dependência matemática relevante para a interpretação: no desenho executado, o padrão produzido pelo algoritmo não se mostrou invariável à composição e à amostragem do conjunto de dados. Em outras palavras, a matemática não “corrige” automaticamente um banco enviesado; ela pode formalizar o viés de seleção e apresentá-lo como padrão.

4.6 Reproduzir o viés para estudá-lo não autoriza usá-lo contra pessoas

O experimento só é eticamente defensável porque a lógica preconceituosa é reproduzida como objeto de auditoria, não como ferramenta de decisão. No Brasil, origem racial ou étnica e dado biométrico vinculado a uma pessoa natural são

dados pessoais sensíveis na LGPD; o fato de uma fotografia já ter sido publicada não elimina os riscos do tratamento. A Recomendação da UNESCO sobre Ética da Inteligência Artificial enfatiza não discriminação, avaliação de impacto, privacidade, rastreabilidade e prevenção da reprodução de estereótipos. O AI Act europeu, por sua vez, restringe usos de avaliação de risco criminal baseada exclusivamente em perfil ou características pessoais e a categorização biométrica destinada a inferir raça (Brasil, 2018; UNESCO, 2022; União Europeia, 2024).

Por isso, este estudo não deve gerar “escore de criminalidade” individual, não deve inferir raça/cor das imagens e não deve ser transformado em endpoint policial, empregatício, securitário ou reputacional. O resultado científico está no diagnóstico da falha: demonstrar que um pipeline pode produzir um número convincente sem possuir fundamento para julgar a pessoa. A reprodução de viés deve permanecer agregada, auditável, minimizada e protegida contra reidentificação (Grother; Ngan; Hanaoka, 2019; ISO, 2021, 2024).

A separação entre o corpus de procurados e o FairFace é parte dessa salvaguarda. No braço externo, os rótulos têm proveniência explícita e ficam restritos à base em que foram fornecidos; no corpus principal, a ausência de raça/cor continua sendo ausência. Não há transferência por nearest neighbor, embeddings, agrupamento ou classificador. Essa escolha evita que uma lacuna documental seja “preenchida” pela própria tecnologia que está sob crítica.

4.7 Contribuição científica e social

A contribuição desta monografia não é encontrar um rosto criminoso; é mostrar por que esse tipo de descoberta pode ser fabricado. A auditoria torna rastreáveis os pontos em que seleção institucional, representação facial, regra de agrupamento, escolha do alvo, hiperparâmetros e avaliação entram na produção do resultado. Ao separar o que é identificável do que não é, o trabalho impede que uma lacuna de dados seja convertida em certeza algorítmica.

A contribuição metodológica é reutilizável além deste caso. Qualquer sistema que atribua a pessoas conceitos como risco, personalidade, empregabilidade, periculosidade, emoção ou orientação política pode sofrer do mesmo problema quando o rótulo é um proxy frágil, endógeno ou socialmente selecionado. O protocolo — origem do rótulo, identificabilidade, controle de vazamento, controles negativos, estabilidade e validade externa — oferece uma forma objetiva de perguntar se o modelo descobriu

algo sobre o mundo ou apenas aprendeu a reproduzir sua própria construção.

O resultado social mais importante é também o mais simples: uma saída matemática não é automaticamente neutra. No braço FairFace, métricas agregadas semelhantes coexistiram com partições diferentes e forte variação entre sementes. Isso não autoriza afirmar discriminação racial no corpus principal, mas mostra por que composição e seleção devem ser auditadas antes de atribuir significado moral ou social a um padrão facial.

5 LIMITAÇÕES E AGENDA DE REPRODUÇÃO

5.1 Validade de construto e de critério

O alvo é sintético e endógeno à geometria facial; não mede criminalidade, culpa, raça/cor, identidade ou equidade. Não existe critério externo observado capaz de validar essas interpretações. A percepção visual que motivou a questão racial permanece uma hipótese, não um resultado: sem raça/cor validada por registro, fonte recuperada e denominadores compatíveis, a monografia não pode estimar quantas pessoas negras, brancas ou de qualquer outro grupo aparecem nas listas nem calcular seletividade racial. Essa ausência não deve ser preenchida por inferência visual ou por classificação automática de raça.

5.2 Validade externa

O corpus decorre de seleção institucional, divulgação, permanência pública, disponibilidade de fotografia, coleta e processamento, sem amostragem probabilística; portanto, os resultados não generalizam automaticamente para criminalidade populacional, outras bases ou outros processos de seleção. No braço demográfico, os rótulos do FairFace são categorias históricas do dataset, não autoidentificação irrestrita nem categorias biológicas. Como cada cenário altera proporções e registros e a estabilidade entre sementes é baixa, o contraste é descritivo e não identifica efeito causal demográfico.

5.3 Validade interna

O `group_id` bloqueia duplicidades prováveis no limiar 0,999. A revisão humana dos pares próximos ao limiar foi concluída sem erros identificados no material revisado, fortalecendo a adequação operacional dessa regra, mas sem garantir identidade única nem excluir duplicidades abaixo do limiar. A sensibilidade executada em quatro limiares mostrou AUC semelhante e conjuntos-alvo muito diferentes nos limiares mais baixos; por isso, 0,999 é tratado como decisão operacional, não como verdade biométrica.

5.4 Validade de conclusão e reprodutibilidade

Em consonância com boas práticas de pesquisa computacional reprodutível (Sandve et al., 2013), a edição definitiva anterior do código e da documentação está congelada na tag `limpa paper-v1.1-final`, commit 6b81953. A proveniência da corrida científica anterior continua registrada como `worktree_dirty=true` e não

é reescrita retroativamente. O SHA-256 do modelo de embedding <w600k_r50.onnx> é 4c06341c33c2ca1f86781dab0e829f88ad5b64be9fba56e56bc9ebdefc619e43; ele foi calculado pelo script <scripts/register_model_hash.py>, registrado em <artifacts/model_hashes.json> e não é atribuído retroativamente à corrida FairFace original. A reexecução principal preserva OOF por observação e ICs de 2.000 reamostragens hierárquicas em <artifacts/primary_oof_confirmatory/>. Grades não executadas — FairFace pareado, ablação de regras, outros clusterings, segundo encoder e multiverse — não sustentam nenhuma afirmação empírica desta versão.

6 CONCLUSÃO

Esta monografia começou com uma provocação: construir uma máquina capaz de parecer reconhecer “criminalidade” em rostos de listas de procurados. O resultado final mostra por que essa aparência é enganosa. O pipeline consegue produzir padrões, escores e métricas internamente coerentes; isso não transforma criminalidade em atributo facial.

Primeiro, o banco de procurados não é uma amostra da criminalidade. Ele é o produto de decisões de investigação, localização, divulgação, jurisdição, vigência, disponibilidade de fotografia e coleta. Logo, qualquer padrão aprendido já nasce condicionado por quem foi selecionado para aparecer. Tratar essa seleção como se fosse uma característica natural das pessoas é o primeiro erro.

Segundo, o desempenho não resolve esse problema. Em 9.482 embeddings, a validação cruzada agrupada com ajuste estritamente no treino alcançou ROC-AUC média de 0,896: o alvo sintético é recuperável. No controle sintético, a ROC-AUC chegou a 1,000 mesmo sem existir qualquer construto social externo. Esses números demonstram que uma regra criada pela própria geometria pode ser aprendida com grande eficiência. Não demonstram criminalidade, culpa, periculosidade ou caráter.

Terceiro, o próprio “padrão” é pouco estável. Em $k = 64$, as medianas entre sementes foram 0,085 para ARI e 0,004 para Jaccard do alvo; perturbações de ordem, `batch_size`, representação e k também estiveram associadas a mudanças na estrutura. Um sistema que muda substancialmente quem pertence ao alvo enquanto continua exibindo métricas altas oferece um alerta direto contra a tentação de reificar clusters como categorias humanas reais.

Quarto, a dimensão racial torna esse alerta socialmente relevante, mas exige precisão. Esta edição não prova que pessoas negras apareçam mais ou menos nas listas de procurados, porque o corpus não possui raça/cor validada e denominadores compatíveis. O braço externo com FairFace mostra algo diferente: perturbações de composição e amostragem demográfica estiveram associadas a mudanças materiais na partição e na identidade do alvo enquanto ROC-AUC e prevalência variaram pouco. O desenho atual não identifica efeito causal demográfico; ele mostra que o padrão do algoritmo variou em associação com quem compôs a base nos cenários executados.

A conclusão, portanto, é direta: não há fundamento matemático neste trabalho para uma “criminalidade facial”. Há, sim, uma demonstração matemática de como um preconceito pode ganhar aparência de objetividade quando seleção institucional,

composição da base e rótulos produzidos pelo próprio sistema são confundidos com fatos sobre pessoas. A matemática do pipeline é real; a passagem dessa matemática para “quem parece criminoso” é inválida. O uso responsável desses resultados é auditar bases e modelos, documentar desigualdades com metadados legítimos e impedir que desempenho algorítmico seja usado para justificar fisiognomia, inferência racial pela face ou pontuação individual de risco.

DECLARAÇÕES

Disponibilidade de código e artefatos. A implementação, os testes, os relatórios e os outputs agregados estão no repositório público no GitHub. A edição definitiva está congelada na tag `paper-v1.1-final`, commit 6b81953; o estado histórico e o manifesto da corrida permanecem diferenciados no texto e no Apêndice A.

Disponibilidade de dados e imagens. O arquivo usado na reconstrução contém 9.584 imagens organizadas por qualidade e está disponível como conjunto de imagens no Kaggle (versão 1, licença CC0 1.0). O depósito preserva registros oriundos de listas públicas do FBI, da Interpol e de polícias brasileiras; não constitui amostra probabilística de pessoas que cometeram crimes, não fornece um rótulo de criminalidade e não altera os limites éticos e inferenciais desta monografia.

Estado de reprodução. O estado canônico desta edição foi congelado na tag `limpa paper-v1.1-final`, commit 6b81953. O manifesto registra hashes das entradas e de 20 outputs, e o braço demográfico permanece isolado em `<research_audit_v2/demographic_composition/>`.

Generative AI Usage Statement. OpenAI Codex foi utilizado para revisão analítica dirigida, depuração do código, execução de testes e ajustes localizados de clareza e terminologia. O autor verificou as alterações, os resultados numéricos e a responsabilidade integral pelo manuscrito. Esta declaração deve ser reavaliada pelo autor diante da política vigente do local de submissão.

Não houve financiamento.

Conflitos de interesse. O autor desenvolveu o repositório auditado; esse conflito intelectual é declarado. Não foram informados conflitos financeiros adicionais nos documentos fornecidos.

Contribuições do autor (CRedit). H. L. Gusmão: Conceitualização; Metodologia; Software; Curadoria de dados; Análise formal; Visualização; Redação — rascunho original; Redação — revisão e edição.

Ética, raça e proteção de dados. Não houve recrutamento, intervenção ou contato com participantes. A auditoria secundária trabalha com artefatos computacionais derivados de fotografias previamente publicadas, mas dados públicos não são automaticamente isentos de risco. No Brasil, origem racial ou étnica e dado biométrico vinculado a pessoa natural integram categorias de dados pessoais sensíveis previstas na LGPD. Os outputs públicos deste estudo são agregados ou pseudonimizados; nomes, URLs, caminhos pessoais, imagens e embeddings individuais são bloqueados pelo scanner fail-closed. Não foram inferidas categorias raciais a partir da aparência, não foram produzidas alegações individuais e não se recomenda uso operacional, reidentificação, decisão automatizada sobre pessoas nem redistribuição desnecessária dos dados faciais. No braço FairFace, foram utilizadas somente as categorias fornecidas pela própria base, mantidas estritamente no domínio externo, sem associação ou transferência para indivíduos do corpus principal. Qualquer extensão racial futura sobre as listas deve usar apenas metadados documentados, justificar finalidade e necessidade, minimizar dados, preservar categorias e incertezas de origem e divulgar somente resultados agregados com proteção contra reidentificação.

REFERÊNCIAS

- BEN-HUR, A.; ELISSEEFF, A.; GUYON, I. A stability based method for discovering structure in clustered data. *Pacific Symposium on Biocomputing*, p. 6–17, 2002. DOI: 10.1142/9789812799623_0002. Disponível em: <https://doi.org/10.1142/9789812799623_0002>. Acesso em: 27 jul. 2026.
- BIRHANE, A. et al. The dark side of dataset scaling: Evaluating racial classification in multimodal models. In: *Proceedings of the ACM Conference on Fairness, Accountability, and Transparency*. Rio de Janeiro: ACM, 2024. DOI: 10.1145/3630106.3658968. Disponível em: <<https://doi.org/10.1145/3630106.3658968>>. Acesso em: 16 ago. 2026.
- BOWYER, K. W. et al. The “criminality from face” illusion. *IEEE Transactions on Technology and Society*, v. 1, n. 4, p. 175–183, 2020. DOI: 10.1109/TTS.2020.3032321.
- BRASIL. *Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD)*. Brasília, DF: Presidência da República, 2018.
- BUOLAMWINI, J.; GEBRU, T. Gender shades: intersectional accuracy disparities in commercial gender classification. In: *Proceedings of Machine Learning Research*. [s.n.], 2018. v. 81, p. 77–91. Disponível em: <<https://proceedings.mlr.press/v81/buolamwini18a.html>>. Acesso em: 27 jul. 2026.
- CHERNOZHUKOV, V. et al. Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, v. 21, n. 1, p. C1–C68, 2018. DOI: 10.1111/ectj.12097. Disponível em: <<https://doi.org/10.1111/ectj.12097>>. Acesso em: 27 jul. 2026.
- CONSELHO NACIONAL DE JUSTIÇA. *Resolução nº 484, de 19 de dezembro de 2022. Estabelece diretrizes para a realização do reconhecimento de pessoas em procedimentos e processos criminais e sua avaliação no âmbito do Poder Judiciário*. Brasília, DF: CNJ, 2022.
- COSTON, A. *Falsifying discriminant validity of predictive algorithms*. 2026. ArXiv:2601.17146. DOI: 10.1145/3805689.3812310. Disponível em: <<https://arxiv.org/abs/2601.17146>>. Acesso em: 16 ago. 2026.
- D’AMOUR, A. et al. Underspecification presents challenges for credibility in modern machine learning. *Journal of Machine Learning Research*, v. 23, n. 226, p. 1–61, 2022. Disponível em: <<https://jmlr.org/papers/v23/20-1335.html>>. Acesso em: 16 ago. 2026.
- DENG, J. et al. Arcface: additive angular margin loss for deep face recognition. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. [s.n.], 2019. p. 4690–4699. DOI: 10.1109/CVPR.2019.00482. Disponível em: <<https://doi.org/10.1109/CVPR.2019.00482>>. Acesso em: 27 jul. 2026.

ELWERT, F.; WINSHIP, C. Endogenous selection bias: the problem of conditioning on a collider variable. *Annual Review of Sociology*, v. 40, p. 31–53, 2014. DOI: 10.1146/annurev-soc-071913-043455. Disponível em: <<https://doi.org/10.1146/annurev-soc-071913-043455>>. Acesso em: 27 jul. 2026.

FAWCETT, T. An introduction to roc analysis. *Pattern Recognition Letters*, v. 27, n. 8, p. 861–874, 2006. DOI: 10.1016/j.patrec.2005.10.010. Disponível em: <<https://doi.org/10.1016/j.patrec.2005.10.010>>. Acesso em: 27 jul. 2026.

GEBRU, T. et al. Datasheets for datasets. *Communications of the ACM*, v. 64, n. 12, p. 86–92, 2021. DOI: 10.1145/3458723. Disponível em: <<https://doi.org/10.1145/3458723>>. Acesso em: 27 jul. 2026.

GROTHER, P.; NGAN, M.; HANAOKA, K. *Face Recognition Vendor Test Part 3: demographic effects*. Gaithersburg, 2019. DOI: 10.6028/NIST.IR.8280. Disponível em: <<https://doi.org/10.6028/NIST.IR.8280>>. Acesso em: 27 jul. 2026.

GUERDAN, L. et al. *Ground(less) Truth: a causal framework for proxy labels in human-algorithm decision-making*. 2023. ArXiv:2302.06503. Disponível em: <<https://arxiv.org/abs/2302.06503>>. Acesso em: 16 ago. 2026.

GUSMÃO, H. L. *Face Profile ML / are-you-a-criminal-ML*. 2026a. GitHub. Estado histórico de referência: commit 734f5979b0b659727c71b07c77ee7f0b9431d2b9. A corrida científica preservada registra git_commit f90298a8962e1b612ec3463bdf1013f6bb0b543b e worktree_dirty=true. Estado canônico da edição definitiva: tag paper-v1.1-final, commit 6b81953. Disponível em: <<https://github.com/limag-henrique/are-you-a-criminal-ML>>. Acesso em: 19 ago. 2026.

GUSMÃO, H. L. *Most Wanted Criminals FBI, Interpol, BR Police*. 2026b. Kaggle, versão 1. Conjunto de 9.584 imagens; licença CC0 1.0. Disponível em: <<https://www.kaggle.com/datasets/henriquelimag/most-wanted-criminals-fbi-interpol-br-police>>. Acesso em: 16 ago. 2026.

HERNÁN, M. A.; HERNÁNDEZ-DÍAZ, S.; ROBINS, J. M. A structural approach to selection bias. *Epidemiology*, v. 15, n. 5, p. 615–625, 2004. DOI: 10.1097/01.ede.0000135174.63482.43. Disponível em: <<https://pubmed.ncbi.nlm.nih.gov/15308962/>>. Acesso em: 27 jul. 2026.

HUBERT, L.; ARABIE, P. Comparing partitions. *Journal of Classification*, v. 2, p. 193–218, 1985. DOI: 10.1007/BF01908075. Disponível em: <<https://doi.org/10.1007/BF01908075>>. Acesso em: 27 jul. 2026.

IBGE. *Censo Demográfico 2022: população por cor ou raça*. Rio de Janeiro: Instituto Brasileiro de Geografia e Estatística, 2022. Resultados do universo divulgados pelo IBGE.

INTERPOL. *About Red Notices*. Lyon: Interpol, 2026a. Disponível em: <<https://www.interpol.int/en/How-we-work/Notices/Red-Notices>>. Acesso em: 27 jul. 2026.

INTERPOL. *View Red Notices*. Lyon: Interpol, 2026b. Disponível em: <<https://www.interpol.int/en/How-we-work/Notices/Red-Notices/View-Red-Notices>>. Acesso em: 27 jul. 2026.

ISO. *ISO/IEC 19795-1:2021: information technology — biometric performance testing and reporting — Part 1: principles and framework*. 2. ed. Geneva, 2021. Disponível em: <<https://www.iso.org/standard/73515.html>>. Acesso em: 27 jul. 2026.

ISO. *ISO/IEC 19795-10:2024: information technology — biometric performance testing and reporting — Part 10: quantifying biometric system performance variation across demographic groups*. Geneva, 2024. Disponível em: <<https://www.iso.org/standard/81223.html>>. Acesso em: 27 jul. 2026.

JACOBS, A. Z.; WALLACH, H. Measurement and fairness. In: *Proceedings of the ACM Conference on Fairness, Accountability, and Transparency*. [s.n.], 2021. p. 375–385. DOI: 10.1145/3442188.3445901. Disponível em: <<https://doi.org/10.1145/3442188.3445901>>. Acesso em: 27 jul. 2026.

KAUFMAN, S. et al. Leakage in data mining: formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, v. 6, n. 4, p. art. 15, 2012. DOI: 10.1145/2382577.2382579. Disponível em: <<https://doi.org/10.1145/2382577.2382579>>. Acesso em: 27 jul. 2026.

KÄRKKÄINEN, K.; JOO, J. Fairface: Face attribute dataset for balanced race, gender, and age for bias measurement and mitigation. In: *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*. [s.n.], 2021. p. 1548–1558. DOI: 10.1109/WACV48630.2021.00159. Disponível em: <<https://doi.org/10.1109/WACV48630.2021.00159>>. Acesso em: 16 ago. 2026.

MITCHELL, M. et al. Model cards for model reporting. In: *Proceedings of the Conference on Fairness, Accountability, and Transparency*. [s.n.], 2019. p. 220–229. DOI: 10.1145/3287560.3287596. Disponível em: <<https://doi.org/10.1145/3287560.3287596>>. Acesso em: 27 jul. 2026.

NIST. *Face Recognition Technology Evaluation: Demographic Effects*. Gaithersburg: National Institute of Standards and Technology, 2026. Disponível em: <https://pages.nist.gov/frvt/html/frvt_demographics.html>. Acesso em: 16 ago. 2026.

PEDREGOSA, F. et al. Scikit-learn: machine learning in python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011. Disponível em: <<https://www.jmlr.org/papers/v12/pedregos11a.html>>. Acesso em: 27 jul. 2026.

RAJI, I. D. et al. The fallacy of ai functionality. In: *Proceedings of the ACM Conference on Fairness, Accountability, and Transparency*. [s.n.], 2022. p. 959–972. DOI: 10.1145/3531146.3533158. Disponível em: <<https://doi.org/10.1145/3531146.3533158>>. Acesso em: 16 ago. 2026.

RAJI, I. D. et al. Closing the ai accountability gap: defining an end-to-end framework for internal algorithmic auditing. In: *Proceedings of the Conference on Fairness, Accountability, and Transparency*. [s.n.], 2020. p. 33–44. DOI: 10.1145/3351095.3372873. Disponível em: <<https://doi.org/10.1145/3351095.3372873>>. Acesso em: 27 jul. 2026.

ROBERTS, D. R. et al. Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, v. 40, n. 8, p. 913–929, 2017. DOI: 10.1111/ecog.02881. Disponível em: <<https://doi.org/10.1111/ecog.02881>>. Acesso em: 27 jul. 2026.

SAITO, T.; REHMSMEIER, M. The precision-recall plot is more informative than the roc plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, v. 10, n. 3, p. e0118432, 2015. DOI: 10.1371/journal.pone.0118432. Disponível em: <<https://doi.org/10.1371/journal.pone.0118432>>. Acesso em: 27 jul. 2026.

SANDVE, G. K. et al. Ten simple rules for reproducible computational research. *PLOS Computational Biology*, v. 9, n. 10, p. e1003285, 2013. DOI: 10.1371/journal.pcbi.1003285. Disponível em: <<https://doi.org/10.1371/journal.pcbi.1003285>>. Acesso em: 27 jul. 2026.

SCHOEFFER, J.; DE-ARTEAGA, M.; ELMER, J. *Perils of label indeterminacy: a case study on prediction of neurological recovery after cardiac arrest*. 2025. ArXiv:2504.04243. Disponível em: <<https://arxiv.org/abs/2504.04243>>. Acesso em: 16 ago. 2026.

SECRETARIA NACIONAL DE POLÍTICAS PENAS. *SENAPPEN realiza oficina nacional para construção de um sistema penal antirracista*. Brasília, DF: Ministério da Justiça e Segurança Pública, 2025.

SURESH, H.; GUTTAG, J. A framework for understanding sources of harm throughout the machine learning life cycle. In: *Proceedings of Equity and Access in Algorithms, Mechanisms, and Optimization*. [s.n.], 2021. p. 1–9. DOI: 10.1145/3465416.3483305. Disponível em: <<https://doi.org/10.1145/3465416.3483305>>. Acesso em: 27 jul. 2026.

UNESCO. *Recommendation on the Ethics of Artificial Intelligence*. Paris: UNESCO, 2022.

UNIÃO EUROPEIA. *Regulamento (UE) 2024/1689 do Parlamento Europeu e do Conselho, de 13 de junho de 2024, que estabelece regras harmonizadas em matéria de inteligência artificial (Artificial Intelligence Act)*. 2024. Jornal Oficial da União Europeia.

VON LUXBURG, U. Clustering stability: an overview. *Foundations and Trends in Machine Learning*, v. 2, n. 3, p. 235–274, 2010. DOI: 10.1561/22000000008. Disponível em: <<https://doi.org/10.1561/22000000008>>. Acesso em: 27 jul. 2026.

APÊNDICE A — RASTREABILIDADE E CONTRATO DE REPRODUÇÃO

Este apêndice distingue o que a auditoria final efetivamente preencheu do que permanece histórico ou não recuperado. A classificação evita transformar documentação posterior em procedimento histórico e registra os elementos necessários para replicação independente.

Quadro A.1 — Status do pacote de reprodução após a corrida final

Componente	Situação final	Classe/status
Validação cruzada agrupada	Ajuste estritamente no treino; <code>model.predict(test)</code> e alvo escolhido no treino	Reconstruído/novo
Auditoria de leakage	5 dobras; 25 eventos; zero <code>test_overlap</code> e <code>outside_train</code>	Novo/verificado
<code>group_id</code>	Similaridade cosseno; limiar 0,999; 9.422 grupos; 59 não unitários	Reconstruído; duplicidade provável
Revisão humana do limiar	Pares próximos ao limiar revisados; nenhum erro identificado no material inspecionado	Verificado, sem equivaler a confirmação de identidade
Métricas por dobra	<code><cross_fitted_metrics.csv></code> e <code><split_composition.csv></code>	Reconstruído/estruturado
Calibração e limiar	Logística e limiar por F1; ambos train-only	Reconstruído
PCA-64	Especificação completa e variância explicada em JSON	Reconstruído; não histórico
Estabilidade	611 execuções; resumo e 60.045 comparações pareadas	Novo/reconstruído
Linhagem	Cinco contagens classificadas; 9.546↔9.584 sem elo	Parcial/não recuperado
Manifesto/ hashes/ privacidade	Manifesto completo, 20 outputs com SHA-256; gates de privacidade	Verificado para corrida atual

Fonte: artefatos da execução final e implementação congelada na tag `paper-v1.1-final`, commit 6b81953. “Reconstruído” não significa reprodução do protocolo histórico.

Quadro A.2 — Especificação da configuração computacional da reconstrução final

Os parâmetros abaixo pertencem à reconstrução final. Onde o procedimento histórico não foi recuperado, isso é indicado explicitamente e nenhuma atribuição retroativa é feita.

Elemento	Configuração final reconstruída	Status histórico / observação
Commit/estado de execução	Corrida: <code>git_commit=f90298a...</code> , <code>worktree_dirty=true</code> ; edição final: <code>paper-v1.1-final</code> em 6b81953	A tag limpa identifica o estado canônico da edição; não altera retroativamente a proveniência da corrida

Elemento	Configuração final reconstruída	Status histórico / observação
Dados analíticos	9.584 registros; 9.482 vetores ArcFace de 512 dimensões	Contagens atuais reproduzidas
Algoritmo de agrupamento	MiniBatchKMeans	Reconstrução atual; regra histórica não recuperada
k	Primário 64; grade 32, 48, 64, 80, 96, 128	Grade final executada; k histórico não recuperado
Sementes	100 sementes explícitas; semente primária = primeira da lista	Reconstrução atual; sementes históricas não recuperadas
batch_size	Primário 1.024; grade 256, 512, 1.024, 2.048, 4.096	Reconstrução atual
max_iter / n_init	100 / 3	Reconstrução atual
Ordens	original, reversed, seeded_shuffle, hashed_index	Sensibilidade operacional atual
Regra do alvo	largest_cluster	Reconstrução atual; histórica não recuperada
group_id	<i>union-find</i> sobre pares de embeddings L2 com cosine similarity $\geq 0,999$	Duplicidade provável, nunca identidade confirmada
PCA-64	64 comp.; randomized; random_state=20260727; centering=true; whiten=false; L2 antes/depois	Reconstrução atual; configuração histórica não recuperada
Validação cruzada agrupada	GroupKFold, 5 dobras; agrupamento/alvo/centroide/calibração/limiar ajustados somente no treino	Reconstrução atual
Calibração	LogisticRegression (lbfgs), train-only	Reconstrução atual
Limiar	Máximo F1 na curva precisão-revocação do treino	Reconstrução atual
Ambiente	Windows 11; Python 3.14.3; NumPy 2.4.2; pandas 3.0.0; scikit-learn 1.9.0; SciPy 1.17.1	Registrado na corrida final
Outputs	20 artefatos listados com SHA-256	Reprodutibilidade atual; outputs não equivalem a histórico Git

Quadro A.3 — Escopo final da estabilidade e controle metodológico

A estabilidade final foi desenhada por fatores separados. As estatísticas completas de ARI, Jaccard, tamanho e prevalência do alvo são artefatos estruturados; o quadro registra somente quantidades e escopo confirmados na evidência recebida.

Bloco	Quantidade/configuração	Interpretação
Estocástico	600 = 100 sementes $\times$ 6 valores de k	Distribuições condicionais por k
Ordem	4 execuções	Sensibilidade operacional à sequência
batch_size	5 execuções	Sensibilidade operacional ao minilote
Representação	2 execuções	original_l2 vs. PCA-64 reconstruída
Total	611/611 execuções	Desenho final completo

Bloco	Quantidade/configuração	Interpretação
Pareadas	60.045 comparações	ARI/Jaccard sem referência arbitrária
Controle sintético	3/3 demonstrações passaram	Demonstração metodológica; não evidência sobre pessoas ou grupos humanos

O controle sintético demonstra apenas que um alvo induzido pela própria geometria pode ser separável e, ao mesmo tempo, sensível a perturbações. Não fornece evidência empírica sobre pessoas procuradas, criminalidade, biometria ou grupos humanos. As análises de estabilidade tampouco identificam uma partição “verdadeira”; medem dependência computacional dentro do desenho executado.