

Material suplementar

Resultados completos de sensibilidades e verificações computacionais. Não inclui fotografias, identificadores pessoais ou resultados parciais da corrida interrompida de 20 sementes por seis valores de k.

S1. Métricas por dobra

Dobra	ROC-AUC	PR-AUC	F1	Brier	group_overlap
0	0.9807961053837342	0.7300965312253792	0.6701030927835051	0.1531575322151184	0
1	0.9669385737238907	0.5557922438586607	0.5757575757575758	0.16555555164813995	0
2	0.8826353992183138	0.33833800619940296	0.37142857142857144	0.20186078548431396	0
3	0.8961263344717241	0.30542894325393494	0.3048780487804878	0.2496035397052765	0
4	0.9206635462555066	0.46422880903516367	0.4625	0.15507282316684723	0

S2. Sensibilidades

Ordem dos registros

factor	setting	ari_vs_baseline	nmi_vs_baseline	target_jaccard	target_size	inertia	iterations	runtime_seconds
record_order	original	1.0	1.0	1.0	429	8786.6953125	4	0.9838430999952834
record_order	random	0.09176856293648201	0.28470067522967724	0.006622516556291391	331	8769.904296875	8	1.51383050000004
record_order	hashed_record_id	0.11260630540241863	0.28397090823438786	0.0011547344110854503	438	8779.0625	7	2.3190285000018775
record_order	reversed	0.11260630540241863	0.28397090823438786	0.0011547344110854503	438	8779.0625	7	8.728327899996657

Minibatch

factor	setting	ari_vs_baseline	nmi_vs_baseline	target_jaccard	target_size	inertia	iterations	runtime_seconds
batch_size	256	0.08562699585912953	0.27697974900783606	0.07142857142857142	1791	8961.943359375	3	3.3097879999986617
batch_size	512	0.09195033291658986	0.2792315654915808	0.12388503468780972	705	8843.3349609375	4	1.6156599999958416
batch_size	1024	1.0	1.0	1.0	429	8786.6953125	4	3.99583469999925
batch_size	2048	0.08735750405859306	0.2810276044005403	0.0	319	8761.642578125	8	9.37821840000106
batch_size	4096	0.07209725846581985	0.26464557847617765	0.0014204545454545	276	8775.49609375	8	16.634922999997798

Representação

representation	dimensions	ari_vs_l2_baseline	nmi_vs_l2_baseline	target_jaccard	target_size	inertia	runtime_seconds	status
original_float32	512	1.0	1.0	1.0	429	8786.6953125	1.913472100000945	sensitivity_only
l2_normalized	512	1.0	1.0	1.0	429	8786.6953125	15.14431709999917	sensitivity_only
centered	512	1.0	1.0	1.0	429	8786.6953125	16.157617099999788	sensitivity_only
pca_64	64	0.10934714012360636	0.27881153193082264	0.0	448	3095.393798828125	0.3584709999995539	sensitivity_only

S3. Duplicidade e determinismo

A deduplicação por similaridade extrema produziu grupos prováveis; o cross-fitting utilizou group_id e não houve grupo atravessando treino e teste. Duas execuções consecutivas em CPU sobre matriz sintética foram bit a bit idênticas; isso não cobre GPU, outro BLAS ou ambiente limpo.

S4. Escopo e exclusões

Controles negativos sintéticos verificaram propriedades esperadas do software, sem validar significado social. Não foram incluídos resultados parciais da corrida interrompida, análise de influência por fonte, análise temporal ou reprodução causal histórica, pois os artefatos necessários não foram localizados.